

Allocation de portefeuille risk-based

Méthodologie, démonstrations et mesure de la performance

Ce document décrit les méthodes implémentées dans la librairie `portopt` : estimation de la covariance, contributions au risque, allocations 1/N, inverse volatilité, risk budgeting, ERC et HRP, backtest walk-forward, indicateurs de performance et de risque, et tests de significativité. Chaque méthode est présentée par son intuition, sa théorie avec démonstrations, un exemple chiffré, des conseils de praticien et son emplacement dans le code.



Auteur	Jean Philippe N'DRI
Version	Septembre 2026
Code	<code>portopt/ Figures docs/make_figures.py</code>

Table des matières

1	Données et rendements	3
1.1	Rendement simple et rendement logarithmique	3
1.2	Alignement temporel	3
1.3	Nettoyage	3
1.4	Prix ajustés	4
2	Estimer la covariance	4
2.1	Covariance empirique	4
2.2	Ledoit-Wolf	4
2.3	EWMA	5
3	La brique commune : contributions au risque	6
3.1	Décomposition d'Euler	6
3.2	Interprétation	6
4	Méthodes d'allocation	7
4.1	Equal Weight (1/N)	7
4.2	Inverse volatilité	7
4.3	Risk budgeting	8
4.4	Equal Risk Contribution (ERC)	9
4.5	Hierarchical Risk Parity (HRP)	11
4.6	Synthèse	13
5	Le backtest walk-forward	13
5.1	Mécanique	14
5.2	Dérive des poids	14
5.3	Coûts de transaction	14
6	Indicateurs de performance	15
6.1	Rendement total et CAGR	15
6.2	Volatility drag	15
6.3	Ratio de Sharpe	16
6.4	Ratio de Sortino	16
6.5	Ratio de Calmar	16
6.6	Hit ratio	17

7 Indicateurs de risque	17
7.1 Volatilité annualisée	17
7.2 Drawdown	17
7.3 VaR et CVaR historiques	19
7.4 Skewness et kurtosis	20
7.5 Turnover	20
8 Significativité statistique	20
8.1 Erreur standard du ratio de Sharpe	20
8.2 Probabilistic Sharpe Ratio	20
8.3 Deflated Sharpe Ratio	21
9 Lecture des résultats de l'exemple	22
10 Checklist de l'expert	25
Références	26

Notations

N, T	nombre d'actifs, nombre d'observations
$R_t \in \mathbb{R}^N$	rendements simples des actifs à la date t (clôture $t - 1$ à clôture t)
$w \in \mathbb{R}^N$	poids du portefeuille, $\mathbf{1}^\top w = 1$, $w \geq 0$ (long-only)
$\Sigma, \sigma_i, \rho_{ij}$	matrice de covariance, volatilités $\sigma_i = \sqrt{\Sigma_{ii}}$, corrélations
$\sigma_p(w)$	volatilité du portefeuille, $\sqrt{w^\top \Sigma w}$
S	covariance empirique
P	nombre de périodes par an ($P = 252$ en quotidien)
L, H	longueur de la fenêtre in-sample, période de détention (backtest)
$\bar{R}, \hat{\sigma}$	moyenne et écart-type empiriques (ddof=1)

Les figures sont produites sur données simulées par `portopt.data.simulate_returns` (10 ETF multi-actifs, 15 ans, régimes de stress et queues épaisses), avec `python docs/make_figures.py`.

1 Données et rendements

1.1 Rendement simple et rendement logarithmique

Définition 1.1. Pour un prix P_t , le rendement simple et le log-rendement sont

$$R_t = \frac{P_t}{P_{t-1}} - 1, \quad r_t = \ln \frac{P_t}{P_{t-1}} = \ln(1 + R_t).$$

Leurs propriétés d'agrégation sont opposées.

	Agrégation en coupe (entre actifs)	Agrégation dans le temps
Simple R	$R_{p,t} = \sum_i w_i R_{i,t}$ exact	$\prod_t (1 + R_t) - 1$
Log r	$r_{p,t} \neq \sum_i w_i r_{i,t}$	$\sum_t r_t$ exact

Proposition 1.2. Le rendement simple d'un portefeuille est la moyenne pondérée des rendements simples des actifs, $R_{p,t} = w^\top R_t$, avec w les poids en valeur en $t-1$. La propriété est fausse pour les log-rendements.

Démonstration. La valeur du portefeuille est $V_t = \sum_i n_i P_{i,t}$ pour des quantités n_i fixes sur la période. Alors

$$\frac{V_t}{V_{t-1}} = \sum_i \frac{n_i P_{i,t-1}}{V_{t-1}} \cdot \frac{P_{i,t}}{P_{i,t-1}} = \sum_i w_i (1 + R_{i,t}),$$

d'où $R_{p,t} = w^\top R_t$. Pour les log-rendements, $r_{p,t} = \ln \sum_i w_i e^{r_{i,t}}$, et par stricte concavité du logarithme (Jensen), $\ln \sum_i w_i e^{r_i} > \sum_i w_i r_i$ dès que les r_i ne sont pas tous égaux. ■

Conséquence. Toute construction de portefeuille et tout backtest se font en rendements simples. Les log-rendements servent à la modélisation statistique (plus symétriques, additifs dans le temps). Relation utile : $r = \ln(1 + R) = R - R^2/2 + O(R^3)$, écart négligeable en quotidien, pas en annuel.

1.2 Alignement temporel

Dans portopt, R_t daté t est le rendement de la clôture $t-1$ à la clôture t . Un poids décidé avec l'information disponible à la clôture $t-1$ gagne R_t . C'est cet alignement qui garantit l'absence de biais d'anticipation (look-ahead) dans le backtest (section 5).

1.3 Nettoyage

`clean_prices` applique trois règles.

1. **Forward-fill limité** (`ffill_limit=5`) : comble les jours fériés quand on mélange des places de cotation. Au-delà, un trou est une vraie absence de donnée.
2. **Jamais de back-fill** : `bfill` recopie un prix futur dans le passé, c'est un biais d'anticipation déguisé.
3. **Les NaN initiaux sont conservés** : un ETF lancé en 2012 a des NaN avant. Le backtester ne l'investit qu'une fois qu'il dispose d'une fenêtre in-sample complète. Supprimer en amont les actifs « incomplets » ne garderait que les survivants : *biais de survie*.

1.4 Prix ajustés

`download_prices(auto_adjust=True)` renvoie des clôtures ajustées des splits et des dividendes, donc des rendements *total return*. Sur des prix bruts, chaque détachement de dividende apparaît comme une perte : un ETF obligataire perdrait artificiellement 3 à 4 % par an.

Dans le code

```
portopt/data.py : download_prices, clean_prices, compute_returns, resample_returns,
load_returns, simulate_returns.
```

2 Estimer la covariance

Toutes les méthodes sauf $1/N$ consomment Σ . La qualité de l'allocation est bornée par la qualité de cet estimateur.

2.1 Covariance empirique

$$S = \frac{1}{T-1} \sum_{t=1}^T (R_t - \bar{R})(R_t - \bar{R})^\top.$$

S est sans biais mais bruitée dès que N/T n'est pas petit. Elle compte $N(N+1)/2$ paramètres : 55 pour 10 actifs, 5 050 pour 100 actifs. Avec $T = 252$, estimer 5 050 paramètres à partir de 25 200 nombres n'a pas de sens. Si $T \leq N$, S est de rang au plus $T - 1$: singulière, non inversible.

Théorème 2.1 (Marchenko et Pastur, 1967). Si les R_t sont iid de covariance I_N et $N, T \rightarrow \infty$ avec $q = N/T \in (0, 1]$, la distribution empirique des valeurs propres de S converge vers une loi à support

$$\lambda \in [(1 - \sqrt{q})^2, (1 + \sqrt{q})^2].$$

Avec $q = 0.5$, les valeurs propres s'étalent entre 0.09 et 2.91 alors qu'elles valent toutes 1. **Les grandes valeurs propres sont surestimées, les petites sous-estimées.** Or toute méthode qui inverse Σ (min-variance, Markowitz) donne le plus de poids aux directions de plus petite variance, précisément celles où l'estimation est la plus fautive : c'est l'*error maximization* de Michaud (1989).

2.2 Ledoit-Wolf

L'idée est de combiner S (sans biais, forte variance) et une cible structurée (biaisée, sans variance). Le compromis biais-variance optimal a une forme fermée (Ledoit et Wolf, 2004).

Définition 2.2 (estimateur de Ledoit-Wolf). Soit S la covariance empirique normalisée par T^1 et $\|A\|^2 = \text{tr}(AA^\top)/N$ la norme de Frobenius normalisée. On pose $\mu = \text{tr}(S)/N$ et

$$d^2 = \|S - \mu I\|^2, \quad \bar{b}^2 = \frac{1}{T^2} \sum_{t=1}^T \|x_t x_t^\top - S\|^2, \quad \delta^* = \frac{\min(\bar{b}^2, d^2)}{d^2},$$

où $x_t = R_t - \bar{R}$. L'estimateur est $\hat{\Sigma} = \delta^* \mu I + (1 - \delta^*) S$.

Interprétation. d^2 mesure l'éloignement de S à la cible (dispersion de ses valeurs propres). $\bar{b}^2$ mesure l'incertitude de S (variance d'échantillonnage estimée à partir des observations). δ^* est

¹L'article et le code utilisent la normalisation $1/T$ pour S dans la formule de shrinkage ; la différence avec $1/(T-1)$ est d'ordre $1/T$.

la fraction de la dispersion observée attribuable au bruit : plus T est petit devant N , plus on contracte.

Propriétés. Pour $\delta^* > 0$, $\hat{\Sigma}$ est définie positive. Les valeurs propres sont contractées vers μ sans changer les vecteurs propres, et le conditionnement s'améliore.

Lemme 2.3 (calcul rapide de $\bar{b}^2$). Avec $S = \frac{1}{T} \sum_t x_t x_t^\top$,

$$\sum_{t=1}^T \|x_t x_t^\top - S\|_F^2 = \sum_{t=1}^T (x_t^\top x_t)^2 - T \|S\|_F^2.$$

Démonstration. $\|x_t x_t^\top - S\|_F^2 = (x_t^\top x_t)^2 - 2 x_t^\top S x_t + \|S\|_F^2$. Or $\sum_t x_t^\top S x_t = \text{tr}(S \sum_t x_t x_t^\top) = T \text{tr}(S^2) = T \|S\|_F^2$. En sommant : $\sum_t (x_t^\top x_t)^2 - 2T \|S\|_F^2 + T \|S\|_F^2$. ■

Le terme $\bar{b}^2$ coûte ainsi $O(TN)$ en plus du calcul de S , sans former les T matrices $x_t x_t^\top$.




Fig. 1. Spectre des valeurs propres, 50 actifs et 75 jours, vrai modèle à un facteur. La covariance empirique écrase les petites valeurs propres (la dernière est plus de 10 fois trop petite) ; Ledoit-Wolf les remonte et divise le conditionnement par 5.

2.3 EWMA

$$\hat{\Sigma}_t = \sum_{s=0}^{T-1} \omega_s (R_{t-s} - \bar{R})(R_{t-s} - \bar{R})^\top, \quad \omega_s \propto \lambda^s, \quad \lambda = 2^{-1/h},$$

avec h la demi-vie (63 jours par défaut), dans l'esprit de RiskMetrics (J.P. Morgan et Reuters, 1996). Le nombre effectif d'observations $(\sum \omega_s)^2 / \sum \omega_s^2 \approx (1 + \lambda)/(1 - \lambda)$ vaut environ 180 jours pour $h = 63$: plus réactif aux changements de régime, mais plus bruité.

Conseil de praticien

- Le choix de l'estimateur de covariance compte souvent plus que le choix entre ERC et HRP.
- La moyenne est bien plus difficile à estimer que la covariance. L'erreur standard d'une moyenne annualisée est $\sigma/\sqrt{Y}$ avec Y le nombre d'années : avec $\sigma = 16\%$ et 10 ans, $\pm 5\%$ sur une moyenne de 8%. Elle ne dépend pas de la fréquence d'échantillonnage. L'erreur sur une

variance décroît avec le nombre d'observations : passer en quotidien aide. C'est la raison de fond pour laquelle toutes les méthodes de ce document ignorent les rendements espérés.

- Au-delà de 50 actifs, préférer un modèle factoriel $\Sigma = B\Sigma_F B^\top + D$ ou le shrinkage non linéaire (Ledoit et Wolf, 2020).

Dans le code

portopt/estimator.py : sample_cov, ledoit_wolf_cov, ewma_cov, estimate_cov. Chaque estimateur accepte cov_method="sample" | "ledoit_wolf" | "ewma" ou un callable returns -> ndarray.

3 La brique commune : contributions au risque

3.1 Décomposition d'Euler

Proposition 3.1. La volatilité $\sigma_p(w) = \sqrt{w^\top \Sigma w}$ est homogène de degré 1 et

$$\sigma_p(w) = \sum_{i=1}^N w_i \frac{\partial \sigma_p(w)}{\partial w_i}, \quad \frac{\partial \sigma_p}{\partial w} = \frac{\Sigma w}{\sigma_p}.$$

Démonstration. $\sigma_p(\lambda w) = \lambda \sigma_p(w)$ pour $\lambda > 0$. On dérive par rapport à λ et on évalue en $\lambda = 1$: $\sum_i w_i \partial_i \sigma_p(w) = \sigma_p(w)$ (théorème d'Euler pour les fonctions homogènes). Le gradient s'obtient en dérivant $\sqrt{w^\top \Sigma w}$. ■

Définition 3.2. Contribution marginale, contribution totale et contribution relative de l'actif i :

$$\text{MRC}_i = \frac{(\Sigma w)_i}{\sigma_p}, \quad \text{RC}_i = w_i \frac{(\Sigma w)_i}{\sigma_p}, \quad \frac{\text{RC}_i}{\sigma_p} = \frac{w_i (\Sigma w)_i}{w^\top \Sigma w}.$$

Par la proposition 3.1, $\sum_i \text{RC}_i = \sigma_p$ et les contributions relatives somment à 1.

3.2 Interprétation

Comme $(\Sigma w)_i = \text{Cov}(R_i, R_p)$,

$$\text{MRC}_i = \frac{\text{Cov}(R_i, R_p)}{\sigma_p} = \rho_{i,p} \sigma_i = \beta_{i,p} \sigma_p.$$

Un actif contribue au risque en proportion de son **bêta au portefeuille**, pas de sa volatilité propre. Un actif très volatil mais décorrélé du portefeuille contribue peu ; un actif avec $\rho_{i,p} < 0$ a une contribution négative : il réduit le risque.

Exemple chiffré

Portefeuille 60/40 actions/obligations, $\sigma_A = 16\%$, $\sigma_O = 6\%$, $\rho = -0.2$.

$$\begin{aligned} \sigma_p^2 &= 0.6^2 \cdot 0.16^2 + 0.4^2 \cdot 0.06^2 + 2 \cdot 0.6 \cdot 0.4 \cdot (-0.2) \cdot 0.16 \cdot 0.06 \\ &= 0.009216 + 0.000576 - 0.000922 = 0.008870, \quad \sigma_p = 9.4\%, \\ (\Sigma w)_A &= 0.6 \cdot 0.0256 + 0.4 \cdot (-0.00192) = 0.014592, \\ \text{RC}_A / \sigma_p &= 0.6 \cdot 0.014592 / 0.008870 = 98.7\%, \quad \text{RC}_O / \sigma_p = 1.3\%. \end{aligned}$$

Un portefeuille 60/40 en capital est un portefeuille 99/1 en risque. C'est la motivation historique du risk parity.

Dans le code

```
portopt.estimator.risk_contributions(w, cov); Backtester.risk_contributions()
```

donne les contributions ex ante à chaque rebalancement.

4 Méthodes d'allocation

Tous les estimateurs partagent la même interface :

```
est = ERC(cov_method="ledoit_wolf").fit(returns_is) # DataFrame T x N sans NaN
est.weights_ # pd.Series, somme 1, long-only
est.cov_ # covariance utilisée
```

4.1 Equal Weight (1/N)

$$w_i = \frac{1}{N}.$$

Intuition. Ne rien estimer, donc ne rien estimer de faux.

Théorie. Si les N actifs ont la même volatilité σ et la même corrélation ρ ,

$$\sigma_p^2 = \frac{\sigma^2}{N} (1 + (N-1)\rho) \xrightarrow{N \rightarrow \infty} \rho \sigma^2 :$$

la diversification élimine le risque idiosyncratique, pas le risque commun.

Résultat clé. DeMiguel et al. (2009) comparent 14 modèles d'optimisation (Markowitz, Bayes-Stein, min-variance contrainte, etc.) sur 7 jeux de données : aucun ne bat significativement 1/N en Sharpe hors échantillon. La fenêtre d'estimation nécessaire pour que Markowitz batte 1/N est de l'ordre de 3 000 mois pour 25 actifs. 1/N est le **benchmark minimal** de toute recherche en allocation.

Limites. Allocation en capital et non en risque : l'actif le plus volatil domine (section 3). Le portefeuille dépend de la définition de l'univers : ajouter 5 ETF actions à un univers de 10 le transforme radicalement.

Conseil de praticien

Le turnover de 1/N n'est pas nul : les poids dérivent avec les prix et il faut rebalancer (38 % par an dans l'exemple de la section 9). Un 1/N en buy-and-hold n'est plus un 1/N au bout de six mois.

Dans le code

```
EqualWeight()
```

4.2 Inverse volatilité

$$w_i = \frac{\sigma_i^{-k}}{\sum_j \sigma_j^{-k}}, \quad k = 1 \text{ (inverse volatilité)}, \quad k = 2 \text{ (inverse variance)}.$$

Intuition. Donner à chaque actif le même budget de volatilité en ignorant les corrélations : $w_i \sigma_i$ constant. On parle aussi de *naive risk parity*.

Proposition 4.1. (i) Si toutes les corrélations sont égales ($\rho_{ij} = \rho$ pour $i \neq j$), le portefeuille inverse volatilité est le portefeuille ERC.

(ii) Si Σ est diagonale, le portefeuille inverse variance est le portefeuille de variance minimale.

Démonstration. (i) Avec $w_i = c/\sigma_i$: $(\Sigma w)_i = \sum_j \rho_{ij} \sigma_i \sigma_j \frac{c}{\sigma_j} = \sigma_i c (1 + (N-1)\rho)$, donc $w_i(\Sigma w)_i = c^2(1 + (N-1)\rho)$ ne dépend pas de i . (ii) Le portefeuille de variance minimale est $w \propto \Sigma^{-1} \mathbf{1}$ et, pour Σ diagonale, $\Sigma^{-1} \mathbf{1} = (1/\sigma_i^2)_i$. ■

InvVol est donc ERC sous l'hypothèse de corrélations homogènes, et l'inverse variance est le min-variance sous l'hypothèse de corrélations nulles. L'écart entre InvVol et ERC mesure l'information apportée par la structure de corrélation.

Conseil de praticien

Avec deux actifs, InvVol et ERC coïncident quelle que soit ρ : il n'y a qu'une corrélation, elle est donc homogène.

Dans le code

```
InverseVolatility(exponent=1)
```

4.3 Risk budgeting

Problème. Étant donné des budgets $b_i > 0$ avec $\sum_i b_i = 1$, trouver $w \geq 0$, $\mathbf{1}^\top w = 1$, tel que

$$\frac{w_i(\Sigma w)_i}{w^\top \Sigma w} = b_i \quad \forall i.$$

C'est un système non linéaire ; l'astuce est de le ramener à un problème convexe.

Théorème 4.2 (Spinu, 2013; Roncalli, 2013). Soit $\Sigma \succ 0$ et

$$y^* = \arg \min_{y \in \mathbb{R}_{++}^N} f(y), \quad f(y) = \frac{1}{2} y^\top \Sigma y - \sum_{i=1}^N b_i \ln y_i.$$

Alors y^* existe et est unique, et $w^* = y^*/\mathbf{1}^\top y^*$ est l'unique portefeuille long-only de risk budgeting. De plus $y^{*\top} \Sigma y^* = 1$.

Démonstration. *Existence.* f est continue sur $\mathbb{R}_{++}^N$. Quand un $y_i \rightarrow 0^+$, $-b_i \ln y_i \rightarrow +\infty$; quand $\|y\| \rightarrow \infty$, $\frac{1}{2} y^\top \Sigma y \geq \frac{1}{2} \lambda_{\min} \|y\|^2$ domine les termes logarithmiques. f est donc coercive et atteint son minimum à l'intérieur de $\mathbb{R}_{++}^N$.

Unicité. $\nabla^2 f(y) = \Sigma + \text{diag}(b_i/y_i^2) \succ 0$: f est strictement convexe.

Condition du premier ordre. $\partial_i f(y) = (\Sigma y)_i - b_i/y_i = 0$, soit $y_i(\Sigma y)_i = b_i$: les contributions au risque non normalisées de y^* sont exactement les budgets.

Normalisation. $y_i(\Sigma y)_i$ est homogène de degré 2, donc les contributions relatives de $w^* = y^*/\mathbf{1}^\top y^*$ valent $b_i/\sum_j b_j = b_i$.

Unicité du portefeuille. Si w est un portefeuille de risk budgeting, alors $y = w/\sqrt{w^\top \Sigma w}$ vérifie $y_i(\Sigma y)_i = b_i$, donc annule ∇f , donc $y = y^*$ par stricte convexité.

Enfin, en sommant les conditions du premier ordre, $y^{*\top} \Sigma y^* = \sum_i b_i = 1$. ■

Algorithme : descente par coordonnées cyclique

On minimise f en y_i seul, les autres coordonnées fixées (Griveau-Billion et al., 2013). La condition du premier ordre en y_i s'écrit

$$\Sigma_{ii} y_i^2 + c_i y_i - b_i = 0, \quad c_i = \sum_{j \neq i} \Sigma_{ij} y_j.$$

Le discriminant $c_i^2 + 4\Sigma_{ii}b_i$ est positif et le produit des racines $-b_i/\Sigma_{ii}$ est négatif : il existe **une seule racine positive**, d'où la mise à jour en forme fermée

$$y_i \leftarrow \frac{-c_i + \sqrt{c_i^2 + 4\Sigma_{ii}b_i}}{2\Sigma_{ii}}.$$

La descente par coordonnées avec minimisation exacte converge vers l'optimum global pour une fonction strictement convexe somme d'un terme lisse et d'un terme séparable (Tseng, 2001).

Algorithme 1 : Risk budgeting par descente par coordonnées (RiskParity._ccd)

Entrées : $\Sigma \succ 0$, budgets b , tolérance $\varepsilon = 10^{-10}$
Sortie : poids w

```

1  $y_i \leftarrow b_i/\sigma_i$  pour tout  $i$ ;  $y \leftarrow y/\sqrt{y^\top \Sigma y}$ ;
2  $s \leftarrow \Sigma y$ ; # maintenu à jour, jamais recalculé
3 répéter
4    $y^{\text{old}} \leftarrow y$ ;
5   pour  $i \leftarrow 1$  à  $N$  faire
6      $c \leftarrow s_i - \Sigma_{ii}y_i$ ;
7      $y'_i \leftarrow (-c + \sqrt{c^2 + 4\Sigma_{ii}b_i})/(2\Sigma_{ii})$ ;
8      $s \leftarrow s + \Sigma_{:,i}(y'_i - y_i)$ ;  $y_i \leftarrow y'_i$ ; #  $O(N)$ 
9 jusqu'à  $\|y - y^{\text{old}}\| \leq \varepsilon \|y\|$ ;
10 retourner  $w = y/\mathbf{1}^\top y$ 
```

Le vecteur Σy est mis à jour incrémentalement : coût $O(N)$ par coordonnée, $O(N^2)$ par cycle, **aucune inversion de matrice**. L'initialisation $y \propto b_i/\sigma_i$ remise à l'échelle $y^\top \Sigma y = 1$ part près de la solution ; en pratique 10 à 50 cycles suffisent.

Usage des budgets. Exprimer une vue en risque plutôt qu'en capital. Dans l'exemple, la stratégie « RB bond tilt » double le budget de TLT, IEF et LQD : les trois portent 45 % du risque (15 % chacun) contre 30 % en ERC.

Conseil de praticien

- Les budgets doivent être strictement positifs (barrière logarithmique). Pour exclure un actif, retirez-le de l'univers.
- Sans contrainte long-only, le système $y_i(\Sigma y)_i = b_i$ admet une solution par orthant, soit jusqu'à 2^{N-1} portefeuilles distincts (Bai et al., 2016). La solution long-only est la seule que l'on veuille en pratique.
- Pour cibler une volatilité (par exemple 10 %), multipliez w par $0.10/\sigma_p$: les contributions relatives sont invariantes au levier.

Dans le code

RiskParity(budgets={...}), méthode _ccd, attribut n_iter_ (nombre de cycles).

4.4 Equal Risk Contribution (ERC)

ERC est le risk budgeting avec $b_i = 1/N$: chaque actif porte la même part du risque.

Théorème 4.3 (Maillard et al., 2010). Soit σ_{MV} la volatilité du portefeuille long-only de variance minimale. Alors

$$\sigma_{MV} \leq \sigma_{ERC} \leq \sigma_{1/N}.$$

Démonstration. La première inégalité est immédiate : le min-variance long-only minimise σ_p sur tout le simplexe, qui contient w_{ERC} .

Pour la seconde, $\sigma_p(w) = \|\Sigma^{1/2}w\|$ est convexe, donc au-dessus de sa tangente en w_{ERC} :

$$\sigma_p\left(\frac{1}{N}\right) \geq \sigma_{ERC} + \nabla \sigma_p(w_{ERC})^\top \left(\frac{1}{N} - w_{ERC}\right) = \frac{1}{N} \sum_i \partial_i \sigma_p(w_{ERC}),$$

car $\nabla \sigma_p(w)^\top w = \sigma_p(w)$ (proposition 3.1). En ERC, $w_i \partial_i \sigma_p = \sigma_{ERC}/N$, donc $\partial_i \sigma_p = \sigma_{ERC}/(Nw_i)$ et

$$\sigma_{1/N} \geq \frac{\sigma_{ERC}}{N^2} \sum_i \frac{1}{w_i} \geq \sigma_{ERC},$$

par l'inégalité arithmético-harmonique : $\sum_i 1/w_i \geq N^2 / \sum_i w_i = N^2$. ■

Interprétation. Dans la paramétrisation du théorème 4.2, y^* minimise aussi $\sqrt{y^\top \Sigma y}$ sous la contrainte $\sum_i \ln y_i \geq c$ (la valeur de c ne change que l'échelle de y^*). ERC est donc un portefeuille de variance minimale sous **contrainte de diversification** logarithmique : sans la contrainte, on retrouve le min-variance ; la contrainte empêche tout poids de tendre vers zéro.




Fig. 2. Deux actifs, $\sigma_1 = 18\%$, $\sigma_2 = 6\%$, $\rho = -0.2$. Le min-variance (5.3 %) met 14 % du risque sur l'actif risqué, 1/N (8.9 %) en met 95 %, ERC (5.7 %) exactement 50 %. La volatilité d'ERC est à peine au-dessus du minimum : on achète beaucoup de diversification pour très peu de variance.

Proposition 4.4. Si tous les actifs ont le même ratio de Sharpe et des corrélations homogènes, ERC est le portefeuille tangent (Sharpe maximal).

Démonstration. Le portefeuille tangent est $w \propto \Sigma^{-1}\mu$. Avec $\mu_i = s\sigma_i$ et $\Sigma = DCD$, $D = \text{diag}(\sigma_i)$, $C = (1 - \rho)I + \rho\mathbf{1}\mathbf{1}^\top$: $\Sigma^{-1}\mu = sD^{-1}C^{-1}\mathbf{1}$. Or $C\mathbf{1} = (1 + (N - 1)\rho)\mathbf{1}$, donc $C^{-1}\mathbf{1} = \mathbf{1}/(1 + (N - 1)\rho)$ et $w \propto D^{-1}\mathbf{1} = (1/\sigma_i)_i$, qui est ERC par la proposition 4.1. ■

Pourquoi ERC fonctionne hors échantillon. Il n'utilise pas les rendements espérés, la quantité la plus mal estimée. Il n'inverse pas Σ : les poids dépendent continûment et de manière stable de Σ , alors que le min-variance amplifie le bruit des petites valeurs propres. Et la proposition 4.4 en fait l'optimum sous une hypothèse d'ignorance raisonnable.

Conseil de praticien

- ERC surpondère les actifs peu volatils (obligations). Sa performance historique doit beaucoup au marché haussier obligataire de 1981 à 2020. En 2022, actions et obligations ont baissé ensemble et les fonds risk parity levés ont perdu de l'ordre de 20 % ou plus.
- Un ERC non levé est peu volatil (8 % dans l'exemple). La comparaison avec 1/N se fait en Sharpe, ou à volatilité égale.

Dans le code

```
ERC(cov_method=...)
```

4.5 Hierarchical Risk Parity (HRP)

Intuition (López de Prado, 2016). Markowitz traite tous les actifs comme des substituts potentiels les uns des autres (graphe complet). Or les actifs ont une structure hiérarchique : SPY et IWM sont proches, TLT et IEF aussi, et ces deux familles sont éloignées. HRP alloue d'abord entre familles, puis à l'intérieur.

Étape 1 : distance

$$d_{ij} = \sqrt{\frac{1}{2}(1 - \rho_{ij})} \in [0, 1].$$

Proposition 4.5. *d est une distance.*

Démonstration. Soit z_i la série de l'actif i centrée et normalisée à norme 1. Alors $\rho_{ij} = z_i^\top z_j$ et $\|z_i - z_j\|^2 = 2(1 - \rho_{ij})$, donc $d_{ij} = \frac{1}{2}\|z_i - z_j\|$. Positivité, symétrie et inégalité triangulaire sont héritées de la norme euclidienne ; $d_{ij} = 0$ si et seulement si $\rho_{ij} = 1$. ■

Étape 2 : clustering hiérarchique

Agglomération successive des deux clusters les plus proches. La distance entre clusters dépend du **linkage** : **single** (minimum des distances, papier original, sensible à l'effet de chaîne), **complete** (maximum, clusters compacts), **average** (moyenne, bon compromis), **ward** (minimise l'augmentation de variance intra-cluster).

Étape 3 : quasi-diagonalisation

On réordonne les actifs selon l'ordre des feuilles du dendrogramme. Les actifs corrélés deviennent voisins et la matrice de covariance réordonnée concentre ses grandes valeurs près de la diagonale.

Étape 4 : bissection récursive

On part de $w = \mathbf{1}$. À chaque découpage d'un cluster en deux sous-clusters L et R :

$$V_c = \tilde{w}_c^\top \Sigma_c \tilde{w}_c, \quad \tilde{w}_c = \frac{\text{diag}(\Sigma_c)^{-1}}{\mathbf{1}^\top \text{diag}(\Sigma_c)^{-1}}, \quad \alpha = 1 - \frac{V_L}{V_L + V_R}, \quad w_L \leftarrow \alpha w_L, \quad w_R \leftarrow (1 - \alpha) w_R.$$

V_c est la variance du portefeuille inverse variance du cluster c : chaque sous-cluster reçoit une part inversement proportionnelle à sa variance. C'est une allocation inverse variance entre deux super-actifs.




Fig. 3. Étapes de HRP. Dans l'ordre arbitraire (gauche), la structure est invisible. Après quasi-diagonalisation (droite), deux blocs apparaissent : taux et crédit (LQD, TLT, IEF) en haut, actifs risqués (VNQ, EEM, EFA, SPY, IWM) en bas, l'or et les matières premières entre les deux.

Algorithme 2 : Hierarchical Risk Parity (HRP)

Entrées : rendements in-sample, linkage, split

Sortie : poids w

1 $\Sigma \leftarrow$ covariance estimée; $\rho \leftarrow$ corrélation;

2 $d_{ij} \leftarrow \sqrt{(1 - \rho_{ij})/2}$;

3 arbre $\leftarrow$ clustering hiérarchique de d (forme condensée);

4 ordre $\leftarrow$ feuilles de l'arbre;

quasi-diagonalisation

5 $w \leftarrow \mathbf{1}$; pile $\leftarrow$ [ordre];

6 **tant que** pile non vide **faire**

7 retirer un cluster c de la pile;

8 **si** $|c| = 1$ **alors** continuer;

9 $(L, R) \leftarrow$ **si** split="bisection" **alors**

10 deux moitiés de la liste c

11 **sinon**

12 deux fils du nœud c

13 $\alpha \leftarrow 1 - V_L / (V_L + V_R)$;

14 $w_L \leftarrow \alpha w_L$; $w_R \leftarrow (1 - \alpha) w_R$;

15 ajouter L et R à la pile;

16 **retourner** w

Proposition 4.6. (i) Aucune inversion de matrice n'est nécessaire : HRP fonctionne même si Σ est singulière ($T < N$). (ii) Si $N = 2$ ou si Σ est diagonale, HRP est le portefeuille inverse variance.

Démonstration. (i) Seules les diagonales des sous-blocs sont inversées. (ii) Pour Σ diagonale, $V_c = 1/S_c$ avec $S_c = \sum_{i \in c} \sigma_i^{-2}$, donc $\alpha = V_R / (V_L + V_R) = S_L / (S_L + S_R)$: le cluster L reçoit la part inverse variance de ses actifs. Par récurrence sur l'arbre, chaque actif reçoit $\sigma_i^{-2} / \sum_j \sigma_j^{-2}$. Le cas $N = 2$ est un unique split entre deux singletons, avec $V_c = \sigma_c^2$. ■

Deux variantes de découpage (split=). "bisection" (papier original) coupe la liste ordonnée en deux moitiés égales, sans respecter l'arbre : un cluster naturel de 3 actifs dans un

univers de 10 peut être coupé en deux. "dendrogram" suit les vrais nœuds du dendrogramme ; c'est la variante recommandée.

Conseil de praticien

- Le code original de López de Prado passe la matrice *carrée* d à `scipy.cluster.hierarchy.linkage`. SciPy interprète alors chaque ligne comme une observation et calcule $\tilde{d}_{ij} = \|d_{\cdot,i} - d_{\cdot,j}\|_2$, une distance de distances. Beaucoup d'implémentations reproduisent ce comportement sans le savoir. `portopt` passe la forme condensée (`squareform`), donc d elle-même.
- HRP est instable dans le temps : un petit changement de corrélation peut réorganiser l'arbre et déplacer beaucoup de poids. Dans l'exemple, son turnover (120 % par an) vaut 2.5 fois celui d'ERC ; à 20 bps de coûts, cela représente 24 bps de performance par an. Essayez `linkage="ward"` ou `"average"`.
- HRP concentre le risque dans le cluster le moins volatil (71 % du risque sur TLT, IEF et LQD dans l'exemple). C'est un portefeuille défensif plus qu'un portefeuille diversifié en risque.

Dans le code

`HRP(linkage="single", split="bisection");` attributs `order_` (ordre quasi-diagonal) et `linkage_matrix_` (à passer à `scipy.cluster.hierarchy.dendrogram`).

4.6 Synthèse

	1/N	InvVol	Risk budgeting / ERC	HRP
Utilise μ	non	non	non	non
Utilise σ_i	non	oui	oui	oui
Utilise ρ_{ij}	non	non	oui	oui (structure)
Inverse Σ	non	non	non	non
Solution	directe	directe	itérative, unique	directe, dépend de l'arbre
Complexité	$O(N)$	$O(N)$	$O(N^2)$ par cycle	$O(N^2)$
Égalise	le capital	$w_i \sigma_i$	$w_i (\Sigma w)_i$	la variance entre clusters
Stabilité des poids	parfaite	très bonne	bonne	moyenne
Point faible	concentration du risque	ignore les corrélations	levier nécessaire	turnover, sensibilité au linkage

Tab. 1. Comparaison des méthodes d'allocation.

5 Le backtest walk-forward

Walk-forward backtest (rolling window)

Weights fitted on returns up to $t-1$ are held on $[t, t+H]$, then the window rolls by H




Fig. 4. Backtest walk-forward à fenêtre glissante. Les poids estimés sur les rendements jusqu'à $t - 1$ sont détenus sur $[t, t + H]$, puis la fenêtre avance de H .

5.1 Mécanique

Algorithme 3 : Backtest walk-forward (Backtester.run)

Entrées : rendements $R_{0..T-1}$, estimateur, L , H , coût c

Sortie : rendements hors échantillon nets de coûts

```

1  $w^{\text{drift}} \leftarrow 0$ ; # départ en cash
2  $t \leftarrow L$ ;
3 tant que  $t < T$  faire
4   fenêtre  $\leftarrow R_{t-L..t-1}$  (rolling) ou  $R_{0..t-1}$  (expanding);
5   univers  $\leftarrow$  actifs sans NaN sur la fenêtre;
6    $w \leftarrow$  copie de l'estimateur ajustée sur la fenêtre;
7    $\tau \leftarrow \sum_i |w_i - w_i^{\text{drift}}|$ ;
8   détenir  $w$  sur  $R_{t..t+H-1}$  avec dérive des poids; richesse  $\times (1 - c\tau)$  en  $t$ ;
9    $w^{\text{drift}} \leftarrow$  poids dérivés en fin de période;  $t \leftarrow t + H$ ;

```

Les poids utilisent l'information jusqu'à $t - 1$ et gagnent R_t : pas de biais d'anticipation. Un test unitaire le vérifie avec un estimateur espion qui enregistre la dernière date qu'il voit. L'estimateur est copié à chaque date : aucun état ne fuit d'une fenêtre à l'autre.

5.2 Dérive des poids

Entre deux rebalancements, un portefeuille réel ne garde pas des poids constants : ils dérivent avec les prix. Pour $k = 1, \dots, H$,

$$V_k = \sum_i w_i \prod_{s=1}^k (1 + R_{i,s}), \quad R_{p,k} = \frac{V_k}{V_{k-1}} - 1, \quad w_i^{\text{drift}} = \frac{w_i \prod_{s=1}^H (1 + R_{i,s})}{V_H}.$$

L'implémentation est vectorisée : `np.cumprod(1 + R, axis=0)` @ `w` donne tout le chemin $V_1, \dots, V_H$ d'un coup. Avec `drift=False`, le portefeuille est supposé rebalancé chaque jour vers la cible, gratuitement : c'est plus optimiste que la réalité.

5.3 Coûts de transaction

Au rebalancement, le turnover one-way est mesuré contre les **poids dérivés** :

$$\tau_t = \sum_i |w_i^{\text{cible}} - w_i^{\text{drift}}|.$$

Mesurer contre la cible précédente est une erreur fréquente : si les actions ont monté de 10 % pendant le mois, un portefeuille ERC doit en vendre même si sa cible n'a pas bougé. Ignorer la dérive sous-estime le turnover.

La richesse est multipliée par $(1 - c\tau_t)$ au rebalancement, c étant donné en points de base (`transaction_cost_bps`). Le premier rebalancement part du cash ($\tau = 1$). Le turnover annualisé, hors construction initiale, est

$$\text{Turnover}_{\text{ann}} = \frac{\sum_{t>t_0} \tau_t}{\text{nombre d'années}},$$

et le coût annuel vaut environ $c \times \text{Turnover}_{\text{ann}}$: 120 % de turnover à 10 bps coûtent 12 bps par an.

Conseil de praticien

- **(L, H) est un hyperparamètre.** Testez une grille et regardez la stabilité du classement des méthodes, jamais le meilleur couple : sinon vous sur-ajustez le backtest.
- **Timing luck.** Décaler la première date de rebalancement de 0 à $H - 1$ jours donne H trajectoires différentes pour la même stratégie. Leur dispersion mesure la part de hasard du résultat ; pour une stratégie mensuelle, elle est souvent du même ordre que les écarts entre méthodes.
- `window="expanding"` réduit le bruit d'estimation mais réagit lentement aux régimes. Une fenêtre glissante de 252 à 756 jours est le standard.

Dans le code

```
Backtester(returns, estimator, in_sample, out_of_sample, window,
transaction_cost_bps, drift); .run() renvoie les rendements hors échantillon nets ; attributs
weights_, turnover_, gross_returns_ ; méthodes annualized_turnover() et
risk_contributions(). run_backtests(returns, {name: est}, ...) compare plusieurs
estimateurs sur la même grille.
```

6 Indicateurs de performance

Toutes les métriques prennent une `pd.Series` (une stratégie) ou un `pd.DataFrame` (une colonne par stratégie) de rendements simples périodiques. `summary()` produit le tableau complet.

6.1 Rendement total et CAGR

$$\text{TR} = \prod_{t=1}^T (1 + R_t) - 1, \quad \text{CAGR} = (1 + \text{TR})^{P/T} - 1.$$

Le CAGR est le taux constant qui donne la même richesse finale : c'est le rendement effectivement vécu par l'investisseur. La moyenne arithmétique annualisée est $\mu_{\text{ann}} = P \bar{R}$.

6.2 Volatility drag

Proposition 6.1. *Le taux de croissance logarithmique $g = \ln(1 + \text{CAGR})$ vérifie, au second ordre,*

$$g \approx \mu_{\text{ann}} - \frac{\sigma_{\text{ann}}^2}{2}.$$

Démonstration. $g = \frac{P}{T} \sum_t \ln(1 + R_t)$. Avec $\ln(1 + R) = R - R^2/2 + O(R^3)$ et $\frac{1}{T} \sum_t R_t^2 = \hat{\sigma}^2 + \bar{R}^2 \approx \hat{\sigma}^2$ en quotidien, $g \approx P\bar{R} - P\hat{\sigma}^2/2 = \mu_{\text{ann}} - \sigma_{\text{ann}}^2/2$. ■

Exemple chiffré

Deux stratégies à $\mu_{\text{ann}} = 8\%$: à $\sigma = 10\%$, $g \approx 7.5\%$; à $\sigma = 30\%$, $g \approx 3.5\%$. Dans l'exemple de la section 9, 1/N a $\mu_{\text{ann}} = 7.36\%$ et $\sigma_{\text{ann}} = 11.42\%$: la formule prédit $g = 7.36\% - 0.65\% = 6.71\%$, le réalisé est $\ln(1.0693) = 6.70\%$.

Conseil de praticien

C'est l'argument le plus solide en faveur de la réduction de variance : à moyenne égale, moins de volatilité donne plus de richesse finale. La version multi-actifs est le *rebalancing premium* ou *excess growth rate* (Fernholz et Shay, 1982 ; Booth et Fama, 1992) : pour un portefeuille à poids constants, $g_p - \sum_i w_i g_i \approx \frac{1}{2}(\sum_i w_i \sigma_i^2 - \sigma_p^2) \geq 0$.

6.3 Ratio de Sharpe

$$\text{SR} = \sqrt{P} \frac{\overline{R - r_f}}{\hat{\sigma}}, \quad r_{f,\text{période}} = (1 + r_{f,\text{ann}})^{1/P} - 1.$$

Rendement excédentaire par unité de risque total. Il est **invariant au levier** : leverer deux fois double l'excès de rendement et la volatilité. Un investisseur moyenne-variance choisit la stratégie de Sharpe maximal puis ajuste le levier.

Annualisation. Le facteur $\sqrt{P}$ n'est valide que pour des rendements iid. Pour des rendements AR(1) d'autocorrélation ρ_1 et un horizon de q périodes grand (Lo, 2002),

$$\text{SR}_q \approx \text{SR}_1 \cdot \sqrt{q} \cdot \sqrt{\frac{1 - \rho_1}{1 + \rho_1}}.$$

Des rendements lissés ($\rho_1 > 0$: hedge funds illiquides, private equity) ont un Sharpe annualisé par $\sqrt{P}$ surestimé.

6.4 Ratio de Sortino

$$\text{Sortino} = \sqrt{P} \frac{\overline{R - \tau}}{DD_\tau}, \quad DD_\tau = \sqrt{\frac{1}{T} \sum_{t=1}^T \min(R_t - \tau, 0)^2}.$$

Seule la volatilité à la baisse est pénalisée. La somme du dénominateur porte sur *toutes* les observations (les positives comptent pour zéro) : diviser par le nombre d'observations négatives est une erreur courante qui gonfle le downside deviation. Pour une distribution symétrique et une moyenne petite devant σ , $DD_0 \approx \sigma/\sqrt{2}$, donc $\text{Sortino} \approx \sqrt{2} \text{SR}$; un rapport nettement supérieur à 1.41 signale une asymétrie positive.

6.5 Ratio de Calmar

$$\text{Calmar} = \frac{\text{CAGR}}{|\text{MaxDD}|}.$$

Nombre d'années de rendement nécessaires pour compenser la pire perte. Il dépend fortement de la longueur de l'historique (le MaxDD ne peut qu'empirer avec T) : ne comparer que des stratégies sur la même période.

6.6 Hit ratio

$$\text{Hit} = \frac{1}{T} \sum_t \mathbb{1}\{R_t > 0\}.$$

Proche de 50 à 55 % pour des stratégies d'allocation en quotidien, et peu informatif seul : un hit ratio de 40 % avec des gains deux fois plus grands que les pertes est excellent (trend following), un hit ratio de 90 % peut cacher une vente de volatilité (petits gains fréquents, pertes rares et énormes).

Dans le code

```
portopt/metric.py : cagr, annualized_mean, annualized_volatility, sharpe_ratio,
sortino_ratio, calmar_ratio, hit_ratio, summary.
```

7 Indicateurs de risque

7.1 Volatilité annualisée

$\sigma_{\text{ann}} = \hat{\sigma}\sqrt{P}$. Mesure symétrique : une hausse de 5 % « coûte » autant qu'une baisse de 5 %. Elle est insuffisante pour des distributions asymétriques ou à queues épaisses (section 7.4).




Fig. 5. Volatilité glissante sur 252 jours. La volatilité réalisée se regroupe par régimes (volatility clustering) : les épisodes de stress simulés doublent la volatilité de toutes les stratégies, mais l'écart entre stratégies reste stable.

7.2 Drawdown

Définition 7.1. Avec la richesse $W_t = \prod_{s \leq t} (1 + R_s)$ et $W_0 = 1$,

$$DD_t = \frac{W_t}{\max(1, \max_{s \leq t} W_s)} - 1, \quad \text{MaxDD} = \min_t DD_t.$$

La durée maximale sous l'eau est la plus longue période consécutive avec $DD_t < 0$.

Le capital initial compte comme un pic : une stratégie qui perd 10 % le premier jour a un drawdown de -10 %, même si W n'a jamais dépassé 0.9.



Fig. 6. Anatomie d'un drawdown : pic, creux, récupération et durée sous l'eau (portefeuille 1/N, données simulées).

Asymétrie des pertes. Récupérer une perte ℓ exige un gain $\ell/(1-\ell)$: -20 % demande +25 %, -50 % demande +100 %.

Conseil de praticien

Pour un mouvement brownien de dérive μ et de volatilité σ (Magdon-Ismail et al., 2004), $\mathbb{E}[\text{MaxDD}] = \sqrt{\pi/2} \sigma \sqrt{T}$ si $\mu = 0$, et $\mathbb{E}[\text{MaxDD}] \sim \frac{\sigma^2}{2\mu} \ln T$ si $\mu > 0$. Le MaxDD dépend donc mécaniquement de la durée du backtest : -15 % sur 5 ans n'est pas comparable à -15 % sur 20 ans.

Drawdowns

Peak-to-trough loss of wealth, dot = maximum drawdown




Fig. 7. Drawdowns des six stratégies de l'exemple ; le point marque le drawdown maximal.

7.3 VaR et CVaR historiques

Définition 7.2. Avec $q_\alpha(R)$ le quantile empirique d'ordre α (5 % par défaut),

$$\text{VaR}_\alpha = -q_\alpha(R), \quad \text{CVaR}_\alpha = -\mathbb{E}[R \mid R \leq q_\alpha(R)],$$

toutes deux exprimées en perte positive.

La VaR à 95 % dit : « 95 % des jours, on ne perd pas plus que cela », sans rien dire des 5 % restants. La CVaR (expected shortfall) dit : « sur les 5 % pires jours, on perd en moyenne cela ».

Daily return distribution and tail risk

1/N portfolio, excess kurtosis 14.1: the normal curve underestimates the tail (shaded)




Fig. 8. Distribution des rendements quotidiens du portefeuille 1/N. La loi normale de mêmes moyenne et écart-type sous-estime la queue gauche (zone ombrée).

Proposition 7.3. La VaR n'est pas sous-additive ; la CVaR est une mesure de risque cohérente (Artzner et al., 1999) : monotone, invariante par translation, positivement homogène et sous-additive.

Contre-exemple de sous-additivité

Deux obligations indépendantes, chacune avec une probabilité de défaut de 4 % (perte 100, sinon 0). Pour chacune, $\text{VaR}_{95\%} = 0$ puisque le défaut est au-delà du quantile à 5 %. Pour le portefeuille des deux, les pertes valent 0, 100 et 200 avec probabilités 92.16 %, 7.68 % et 0.16 % : $\text{VaR}_{95\%} = 100 > 0 + 0$. La VaR pénalise la diversification. Côté CVaR, chaque obligation a $\text{CVaR}_{95\%} = (4\% \times 100)/5\% = 80$, et le portefeuille $(0.16\% \times 200 + 4.84\% \times 100)/5\% = 103.2 \leq 160$: la sous-additivité est respectée.

Le cadre FRTB (Bâle III) a remplacé la VaR à 99 % par l'expected shortfall à 97.5 % pour le risque de marché.

Conseil de praticien

La VaR paramétrique gaussienne $-(\mu + z_\alpha \sigma)$ sous-estime systématiquement le risque de queue. Pour rester paramétrique, utilisez l'expansion de Cornish-Fisher, qui corrige le quantile par la skewness et la kurtosis.

7.4 Skewness et kurtosis

$$\gamma_3 = \frac{\mathbb{E}[(R - \mu)^3]}{\sigma^3}, \quad \gamma_4 = \frac{\mathbb{E}[(R - \mu)^4]}{\sigma^4}, \quad \text{kurtosis excédentaire} = \gamma_4 - 3.$$

$\gamma_3 < 0$ signale une queue gauche épaisse (pertes rares mais grandes : portage, vente d'options, crédit). $\gamma_4 - 3 > 0$ (leptokurtique) signale plus de jours calmes et plus de jours extrêmes qu'une gaussienne ; en quotidien, 5 à 20 est courant pour les indices actions.

Conseil de praticien

Ces moments d'ordre élevé sont très mal estimés : un seul jour extrême peut faire basculer la skewness de -1 à $+1$. Regardez-les sur des sous-périodes avant d'en tirer une conclusion.

7.5 Turnover

Défini à la section 5. C'est un indicateur de risque d'implémentation : un turnover élevé expose aux coûts, à l'impact de marché et à une capacité limitée.

Dans le code

```
max_drawdown, max_drawdown_duration, drawdown_series, value_at_risk,
conditional_value_at_risk, skewness, excess_kurtosis.
```

8 Significativité statistique

Un backtest est une réalisation d'un processus aléatoire. Avant de conclure qu'une stratégie en bat une autre, il faut vérifier que l'écart se distingue du bruit.

8.1 Erreur standard du ratio de Sharpe

Pour des rendements iid gaussiens (Lo, 2002), en unités annuelles sur Y années,

$$\text{se}(\widehat{\text{SR}}) \approx \sqrt{\frac{1 + \frac{1}{2}\text{SR}_{\text{période}}^2}{Y}} \approx \frac{1}{\sqrt{Y}}.$$

Pour qu'un Sharpe de 0.5 soit significativement positif à 95 %, il faut $Y \geq (1.96/0.5)^2 \approx 15$ ans ; pour un Sharpe de 1, environ 4 ans. La plupart des backtests de 10 ans ne distinguent pas un Sharpe de 0.5 d'un Sharpe nul.

Conséquence pour l'exemple

Les Sharpe vont de 0.64 (1/N) à 0.88 (HRP) sur 14 ans, avec une erreur standard d'environ $1/\sqrt{14} = 0.27$. L'écart de 0.24 est inférieur à une erreur standard : on ne peut pas affirmer que HRP bat 1/N. Le test d'écart de Sharpe entre deux stratégies corrélées (Jobson et Korkie, 1981 ; Memmel, 2003) a une erreur standard plus faible, mais du même ordre ici.

8.2 Probabilistic Sharpe Ratio

Définition 8.1 (Bailey et López de Prado, 2012).

$$\text{PSR}(\text{SR}^*) = \Phi \left(\frac{(\widehat{\text{SR}} - \text{SR}^*)\sqrt{T-1}}{\sqrt{1 - \gamma_3 \widehat{\text{SR}} + \frac{\gamma_4 - 1}{4} \widehat{\text{SR}}^2}} \right),$$

How precise is an estimated Sharpe ratio?

95% confidence band, iid returns: $se \approx \sqrt{[(1 + SR^2/2) / T]}$, T in years




Fig. 9. Bande de confiance à 95 % du Sharpe estimé en fonction de la longueur de l'historique.

où $\widehat{SR}$ et SR^* sont exprimés *par période* (non annualisés), γ_3 est la skewness et γ_4 la kurtosis non excédentaire. C'est la probabilité que le vrai Sharpe dépasse le seuil SR^* .

Lecture du dénominateur. Une skewness négative ou une kurtosis élevée augmentent la variance de $\widehat{SR}$, donc baissent le PSR. Une stratégie de vente de volatilité avec un beau Sharpe mais $\gamma_3 = -3$ aura un PSR bien plus faible qu'une stratégie de trend following de même Sharpe avec $\gamma_3 > 0$. `summary()` affiche $PSR(SR > 0)$; au-dessus de 0.95, le Sharpe est significativement positif.

8.3 Deflated Sharpe Ratio

Si l'on a testé K variantes (paramètres, univers, méthodes) et gardé la meilleure, son Sharpe est biaisé à la hausse : même si tous les vrais Sharpe sont nuls, le maximum de K Sharpe estimés est positif. Le DSR (Bailey et López de Prado, 2014) remplace SR^* dans le PSR par l'espérance du maximum de K Sharpe nuls :

$$SR_K^* \approx \sqrt{\text{Var}(\widehat{SR}_k)} \left[(1 - \gamma_E) \Phi^{-1}\left(1 - \frac{1}{K}\right) + \gamma_E \Phi^{-1}\left(1 - \frac{1}{Ke}\right) \right],$$

avec $\gamma_E \approx 0.5772$ la constante d'Euler-Mascheroni et $\text{Var}(\widehat{SR}_k)$ la variance des Sharpe observés sur les K essais. Avec $K = 100$, le crochet vaut $0.4228 \times 2.326 + 0.5772 \times 2.680 \approx 2.53$: il faut un Sharpe observé d'environ 2.5 erreurs standard pour ne pas relever du pur data mining.

Conseil de praticien

Notez le nombre de variantes testées. C'est une donnée du backtest aussi importante que le Sharpe lui-même.

Dans le code

`probabilistic_sharpe_ratio(r, sr_benchmark=0.0)` ; le seuil `sr_benchmark` est donné annualisé et converti en interne.

9 Lecture des résultats de l'exemple

`python examples/run_backtest.py --synthetic` : 10 ETF simulés, fenêtre in-sample de 252 jours, rebalancement tous les 21 jours, 5 bps de coûts, de décembre 2010 à juin 2024 (3 528 jours hors échantillon).




Fig. 10. Croissance de 1 hors échantillon, nette de coûts, échelle logarithmique.

	1/N	InvVol	RB bond tilt	ERC	ERC LW	HRP
CAGR	6.9 %	6.6 %	6.1 %	6.2 %	6.2 %	6.1 %
Volatilité	11.4 %	8.9 %	7.7 %	8.2 %	8.4 %	7.0 %
Sharpe	0.64	0.76	0.81	0.77	0.76	0.88
Sortino	0.93	1.11	1.20	1.14	1.12	1.33
Calmar	0.25	0.32	0.34	0.33	0.32	0.41
Max DD	-27.3 %	-20.5 %	-18.0 %	-19.0 %	-19.5 %	-15.0 %
CVaR 95 % (jour)	1.7 %	1.3 %	1.1 %	1.2 %	1.2 %	1.0 %
Turnover annuel	38 %	41 %	45 %	49 %	48 %	120 %

Tab. 2. Indicateurs hors échantillon, nets de coûts.

Ce qu'il faut en retenir.

1. **1/N a le meilleur CAGR mais le pire risque.** Il est simplement plus exposé aux actifs risqués, qui ont le meilleur rendement sur la période. Son Sharpe est le plus faible.
2. **Toutes les méthodes risk-based améliorent le Sharpe et réduisent le drawdown,** de 25 à 45 %. C'est le résultat robuste de la littérature.
3. **L'ordre entre ERC, InvVol et HRP n'est pas significatif** (section 8). Ne pas conclure que HRP est la meilleure méthode sur ce backtest.
4. **ERC LW $\approx$ ERC** : avec 10 actifs et 252 jours ($q \approx 0.04$), le shrinkage est faible (δ^* médian de 4 %, 15 % au maximum). Il devient décisif à partir d'une cinquantaine d'actifs.
5. **Le coût caché de HRP est son turnover,** 2.5 fois celui d'ERC.

Ces deux tableaux résument la différence entre les méthodes mieux que n'importe quelle métrique.

Key metrics

Out-of-sample, net of costs. Turnover is one-way, per year




Fig. 11. Indicateurs clés par stratégie.

Average capital allocation

Mean target weight across rebalancings

	SPY	EFA	EEM	IWM	TLT	IEF	LQD	GLD	DBC	VNQ
1/N	10%	10%	10%	10%	10%	10%	10%	10%	10%	10%
InvVol	8%	8%	6%	6%	10%	21%	19%	9%	7%	6%
RB bond tilt	6%	6%	4%	5%	14%	29%	18%	7%	7%	4%
ERC	7%	7%	5%	6%	13%	26%	14%	9%	8%	5%
ERC LW	7%	7%	5%	6%	14%	24%	14%	10%	8%	5%
HRP	3%	4%	3%	2%	6%	39%	28%	7%	4%	3%

Fig. 12. Allocation moyenne du capital.




Fig. 13. Allocation moyenne du risque (contributions relatives ex ante).

- **1/N** : capital égal (10 % partout) mais 79 % du risque sur les actifs de type actions (SPY, EFA, EEM, IWM, VNQ). Les Treasuries contribuent à 0 %, voire négativement, grâce à leur corrélation négative.
- **ERC** : risque exactement égal (10 % partout), au prix de 39 % du capital sur IEF et TLT.
- **RB bond tilt** : les budgets doublés sur TLT, IEF et LQD sont respectés (15 % chacun).
- **HRP** : 73 % du capital et 71 % du risque sur les trois ETF obligataires, dont 67 % du capital sur IEF et LQD seuls. La bissection a traité le bloc taux comme l'autre moitié de l'univers et lui a donné un poids massif en tant que cluster peu volatil.




Fig. 14. Poids ERC au fil des rebalancements.

ERC ajuste ses poids de façon continue et lisse. HRP saute d'une configuration à l'autre quand l'arbre de clustering change : c'est l'origine visible de son turnover.




Fig. 15. Poids HRP au fil des rebalancements.

10 Checklist de l'expert

Données

- ☐ Prix ajustés (total return), jamais de rendements sur prix bruts.
- ☐ Pas de back-fill, pas de suppression des actifs à historique court.
- ☐ Rendements simples pour le portefeuille.

Estimation

- ☐ Ratio N/T vérifié; au-delà de 0.1, shrinkage ou modèle factoriel.
- ☐ Rendements espérés jamais utilisés sans prior fort ou shrinkage massif.

Backtest

- ☐ Poids calculés avec l'information jusqu'à $t - 1$ uniquement.
- ☐ Dérive des poids modélisée, turnover mesuré contre les poids dérivés.
- ☐ Coûts réalistes (5 à 20 bps sur ETF liquides, davantage sur small caps et émergents).
- ☐ Robustesse testée sur une grille (L, H) et sur les décalages de rebalancement.
- ☐ Benchmark $1/N$ systématiquement inclus.

Évaluation

- ☐ Comparaison en Sharpe, ou à volatilité égale, pas en CAGR brut.
- ☐ Erreur standard du Sharpe calculée avant toute conclusion.
- ☐ PSR pour la non-normalité, DSR si plusieurs variantes ont été testées.
- ☐ Drawdowns et CVaR examinés, pas seulement la volatilité.
- ☐ Contributions au risque inspectées : savoir où est le risque.
- ☐ Sous-périodes et régimes analysés : la performance d'ensemble peut venir d'un seul épisode.

Références

- Artzner, P., Delbaen, F., Eber, J.-M., Heath, D. (1999). Coherent measures of risk. *Mathematical Finance*, 9(3), 203–228.
- Bai, X., Scheinberg, K., Tütüncü, R. (2016). Least-squares approach to risk parity in portfolio selection. *Quantitative Finance*, 16(3), 357–376.
- Bailey, D. H., López de Prado, M. (2012). The Sharpe ratio efficient frontier. *Journal of Risk*, 15(2), 3–44.
- Bailey, D. H., López de Prado, M. (2014). The deflated Sharpe ratio : correcting for selection bias, backtest overfitting and non-normality. *Journal of Portfolio Management*, 40(5), 94–107.
- Booth, D. G., Fama, E. F. (1992). Diversification returns and asset contributions. *Financial Analysts Journal*, 48(3), 26–32.
- DeMiguel, V., Garlappi, L., Uppal, R. (2009). Optimal versus naive diversification : how inefficient is the 1/N portfolio strategy ? *Review of Financial Studies*, 22(5), 1915–1953.
- Fernholz, R., Shay, B. (1982). Stochastic portfolio theory and stock market equilibrium. *Journal of Finance*, 37(2), 615–624.
- Griveau-Billion, T., Richard, J.-C., Roncalli, T. (2013). A fast algorithm for computing high-dimensional risk parity portfolios. SSRN 2325255.
- Jobson, J. D., Korkie, B. M. (1981). Performance hypothesis testing with the Sharpe and Treynor measures. *Journal of Finance*, 36(4), 889–908.
- Ledoit, O., Wolf, M. (2004). A well-conditioned estimator for large-dimensional covariance matrices. *Journal of Multivariate Analysis*, 88(2), 365–411.
- Ledoit, O., Wolf, M. (2020). Analytical nonlinear shrinkage of large-dimensional covariance matrices. *Annals of Statistics*, 48(5), 3043–3065.
- Lo, A. W. (2002). The statistics of Sharpe ratios. *Financial Analysts Journal*, 58(4), 36–52.
- López de Prado, M. (2016). Building diversified portfolios that outperform out of sample. *Journal of Portfolio Management*, 42(4), 59–69.
- Magdon-Ismaïl, M., Atiya, A. F., Pratap, A., Abu-Mostafa, Y. S. (2004). On the maximum drawdown of a Brownian motion. *Journal of Applied Probability*, 41(1), 147–161.
- Maillard, S., Roncalli, T., Teiletche, J. (2010). The properties of equally weighted risk contribution portfolios. *Journal of Portfolio Management*, 36(4), 60–70.
- Marchenko, V. A., Pastur, L. A. (1967). Distribution of eigenvalues for some sets of random matrices. *Mathematics of the USSR-Sbornik*, 1(4), 457–483.
- Memmel, C. (2003). Performance hypothesis testing with the Sharpe ratio. *Finance Letters*, 1, 21–23.
- Michaud, R. O. (1989). The Markowitz optimization enigma : is optimized optimal ? *Financial Analysts Journal*, 45(1), 31–42.
- J.P. Morgan, Reuters (1996). *RiskMetrics : Technical Document*, 4^e édition. New York.
- Roncalli, T. (2013). *Introduction to Risk Parity and Budgeting*. Chapman & Hall/CRC.
- Spinu, F. (2013). An algorithm for computing risk parity weights. SSRN 2297383.
- Tseng, P. (2001). Convergence of a block coordinate descent method for nondifferentiable minimization. *Journal of Optimization Theory and Applications*, 109(3), 475–494.