


Allocation de portefeuille risk-based

Guide de la librairie portopt :
définitions, résultats et démonstrations

portopt compare des règles d'allocation fondées sur le risque (1/N, inverse volatilité, risk budgeting, ERC, HRP) dans un backtest walk-forward, puis mesure leur performance et leur risque. Ce guide présente d'abord la librairie, puis chaque brique avec la même structure : définition, résultat, démonstration, appel dans le code. Tout résultat énoncé est soit démontré, soit signalé comme admis avec sa référence.



Auteur	Jean Philippe N'DRI
Version	Septembre 2026
Code	portopt/


Table des matières

1	Prise en main	2
1.1	Ce que fait la librairie	2
1.2	Premier backtest	2
1.3	Écrire sa propre règle	2
1.4	Carte de l'API	3
1.5	Notations	3
2	Rendements et portefeuille	3
3	Estimer la covariance	4
4	Contributions au risque	6
5	Règles d'allocation	6
5.1	Equal Weight ($1/N$)	6
5.2	Inverse volatilité	7
5.3	Risk budgeting	7
5.4	Equal Risk Contribution (ERC)	8
5.5	Hierarchical Risk Parity (HRP)	8
5.6	Synthèse	10
6	Backtest walk-forward	10
7	Indicateurs de performance	12
8	Indicateurs de risque	13
9	Significativité statistique	15
10	Exemple complet	16
	Références	18

1 Prise en main

1.1 Ce que fait la librairie

portopt répond à une question : *quelle règle d'allocation aurait donné le meilleur couple rendement/risque, sans utiliser d'information future ?* Elle suit un flux en quatre étapes, un module par étape.



1. **data** télécharge des prix, les nettoie et calcule les rendements R , un `DataFrame` de T dates par N actifs (section 2).
2. **estimator** transforme une fenêtre de rendements en poids w : c'est la *règle d'allocation* (sections 3 à 5).
3. **backtester** applique la règle à chaque date de rebalancement, fait vivre le portefeuille entre deux dates et renvoie ses rendements hors échantillon R_p (section 6).
4. **metric** et **plot** résument ces rendements en indicateurs et en graphiques (sections 7 à 9).

1.2 Premier backtest

```
pip install -e ".[dev]" # numpy, pandas, scipy, yfinance, matplotlib, pytest
```

```

from portopt import load_returns, EqualWeight, ERC, HRP, run_backtests, summary
from portopt import plot

# 1. data : rendements quotidiens, T dates x N actifs
R = load_returns(["SPY", "TLT", "GLD", "DBC", "EFA"], start="2008-01-01")

# 2. estimator : les regles d'allocation a comparer
rules = {"1/N": EqualWeight(), "ERC": ERC(), "HRP": HRP()}

# 3. backtester : fenetre de 252 jours, rebalancement tous les 21 jours
rets, bts = run_backtests(R, rules, in_sample=252, out_of_sample=21,
                          transaction_cost_bps=5)

# 4. metric et plot
print(summary(rets))
plot.save_report(rets, bts, "outputs/charts")

```

`rets` contient un rendement quotidien hors échantillon par stratégie, et `bts["ERC"].weights_` les poids d'ERC à chaque rebalancement. Sans accès réseau, la fonction `simulate_returns()` du module `data` fournit un univers simulé de 10 ETF.

1.3 Écrire sa propre règle

Une règle hérite de `BaseEstimator` et implémente `_compute_weights`. Le backtester l'accepte telle quelle.

```

import numpy as np
from portopt import BaseEstimator

```

```
class InverseVariance(BaseEstimator):
    def _compute_weights(self, returns):
        cov = self._cov(returns)          # applique cov_method
        return 1.0 / np.diag(cov)
```

`fit` fait le reste : il refuse les fenêtres contenant des valeurs manquantes, met à zéro les poids négatifs, normalise la somme à 1 et stocke le résultat dans `weights_`, une `pd.Series` indexée par actif.

1.4 Carte de l'API

Objet	Rôle	Section
<code>load_returns</code> , <code>download_prices</code>	obtenir des prix et des rendements	2
<code>clean_prices</code> , <code>compute_returns</code>	nettoyer, calculer les rendements	2
<code>simulate_returns</code>	univers simulé pour travailler hors ligne	2
<code>estimate_cov</code> , <code>ledoit_wolf_cov</code> , <code>ewma_cov</code>	estimer la covariance	3
<code>risk_contributions</code>	contributions au risque	4
<code>EqualWeight</code> , <code>InverseVolatility</code>	règles sans optimisation	5.1 , 5.2
<code>RiskParity</code> , <code>ERC</code>	risk budgeting, contributions égales	5.3 , 5.4
<code>HRP</code>	Hierarchical Risk Parity	5.5
<code>Backtester</code> , <code>run_backtests</code>	backtest walk-forward	6
<code>summary</code> , module <code>metric</code>	indicateurs de performance et de risque	7–9
<code>plot.save_report</code>	rapport graphique (PNG)	10

1.5 Notations

N, T	nombre d'actifs, nombre de dates
$R_t \in \mathbb{R}^N$	rendements simples des actifs, de la clôture $t-1$ à la clôture t
Δ_N	$\{w \in \mathbb{R}^N : w \geq 0, \mathbf{1}^\top w = 1\}$, ensemble des portefeuilles long-only
$\Sigma, \sigma_i, \rho_{ij}$	covariance, volatilités $\sigma_i = \sqrt{\Sigma_{ii}}$, corrélations
P	nombre de périodes par an (252 en quotidien)
L, H	longueur de la fenêtre d'estimation, période de détention
$\bar{R}, \hat{\sigma}$	moyenne et écart-type empiriques
Φ, φ	fonction de répartition et densité de la loi normale centrée réduite

2 Rendements et portefeuille

Définition 2.1 (rendements). Pour un prix P_t ajusté des dividendes et des splits, le rendement simple et le log-rendement sont

$$R_t = \frac{P_t}{P_{t-1}} - 1, \quad r_t = \ln \frac{P_t}{P_{t-1}} = \ln(1 + R_t).$$

Définition 2.2 (portefeuille). Un portefeuille est un vecteur $w \in \Delta_N$: w_i est la part de la valeur investie dans l'actif i . On note $R_{p,t}$ son rendement.

Proposition 2.3. Si w sont les poids en $t-1$, alors $R_{p,t} = w^\top R_t$. L'égalité analogue est fausse pour les log-rendements.

Démonstration. Soit n_i le nombre de titres i détenus et $V_t = \sum_i n_i P_{i,t}$. Alors $V_t/V_{t-1} = \sum_i \frac{n_i P_{i,t-1}}{V_{t-1}} \cdot \frac{P_{i,t}}{P_{i,t-1}} = \sum_i w_i (1 + R_{i,t})$, d'où $R_{p,t} = w^\top R_t$. Pour les log-rendements, $r_{p,t} =$

$\ln \sum_i w_i e^{r_{i,t}}$, qui est strictement supérieur à $\sum_i w_i r_{i,t}$ dès que les $r_{i,t}$ diffèrent (stricte concavité du logarithme). ■

Toute la librairie travaille donc en **rendements simples**.

Définition 2.4 (volatilité du portefeuille). Si Σ est la covariance des rendements, la variance et la volatilité du portefeuille w sont $\sigma_p^2(w) = w^\top \Sigma w$ et $\sigma_p(w) = \sqrt{w^\top \Sigma w}$.

Définition 2.5 (annualisation). Pour des rendements de fréquence P par an : $\mu_{\text{ann}} = P \bar{R}$ et $\sigma_{\text{ann}} = \sqrt{P} \hat{\sigma}$.

Proposition 2.6. Si les rendements des P périodes d'une année sont indépendants, de moyenne μ et de variance σ^2 , et si le rendement annuel est leur somme, alors il a pour moyenne $P\mu$ et pour écart-type $\sqrt{P}\sigma$.

Démonstration. L'espérance est linéaire, et par indépendance la variance d'une somme est la somme des variances : $\text{Var}(\sum_{k=1}^P X_k) = P\sigma^2$. ■

L'additivité est exacte pour les log-rendements et vraie au premier ordre pour les rendements simples quotidiens. C'est ce qui justifie les facteurs P et $\sqrt{P}$.

Dans le code

`load_returns(tickers, start, end, cache_dir="data_cache")` télécharge des prix ajustés, les nettoie et renvoie des rendements simples. Le nettoyage (`clean_prices`) comble les trous d'au plus 5 jours avec la dernière valeur connue, ne comble jamais avec une valeur future, et conserve les valeurs manquantes d'un actif pas encore coté : le backtester ne l'investit qu'une fois son historique complet.

3 Estimer la covariance

Toutes les règles sauf 1/N utilisent une estimation de Σ sur la fenêtre.

Définition 3.1 (covariance empirique). Sur une fenêtre de T dates, avec $x_t = R_t - \bar{R}$: $S = \frac{1}{T-1} \sum_{t=1}^T x_t x_t^\top$.

S est sans biais mais bruitée. Elle compte $N(N+1)/2$ paramètres et, si $T \leq N$, elle est de rang au plus $T-1$, donc non inversible.

Théorème 3.2 (Marchenko-Pastur). Si les R_t sont indépendants de covariance I_N et $N, T \rightarrow \infty$ avec $N/T \rightarrow q \in (0, 1]$, les valeurs propres de S se répartissent sur $[(1-\sqrt{q})^2, (1+\sqrt{q})^2]$. (admis, [Marchenko et Pastur, 1967](#))

Même si toutes les vraies valeurs propres valent 1, celles de S s'étalent de 0.09 à 2.91 pour $q = 0.5$. Les petites valeurs propres sont sous-estimées, et ce sont précisément celles qu'une inversion de Σ amplifie.

Définition 3.3 (Ledoit-Wolf). Soit $S_T = \frac{1}{T} \sum_t x_t x_t^\top$, $\|A\|^2 = \text{tr}(AA^\top)/N$ et $\mu = \text{tr}(S_T)/N$. On pose

$$d^2 = \|S_T - \mu I\|^2, \quad \bar{b}^2 = \frac{1}{T^2} \sum_{t=1}^T \|x_t x_t^\top - S_T\|^2, \quad \delta^* = \frac{\min(\bar{b}^2, d^2)}{d^2} \in [0, 1], \quad \hat{\Sigma} = \delta^* \mu I + (1-\delta^*) S_T.$$

d^2 mesure l'écart de S_T à la cible μI , $\bar{b}^2$ le bruit d'estimation de S_T ; δ^* est la part de

l'écart attribuée au bruit. Ce choix minimise asymptotiquement l'erreur quadratique parmi les combinaisons de S_T et μI (admis, [Ledoit et Wolf, 2004](#)).

Proposition 3.4. Soit $\lambda_1 \geq \dots \geq \lambda_N$ les valeurs propres de S_T et $\delta^* > 0$.

(i) $\hat{\Sigma}$ a les mêmes vecteurs propres que S_T , pour valeurs propres $\delta^* \mu + (1 - \delta^*) \lambda_j$, et elle est définie positive.

(ii) Son conditionnement $\lambda_{\max}/\lambda_{\min}$ est inférieur à celui de S_T .

Démonstration. (i) Si $S_T v = \lambda v$, alors $\hat{\Sigma} v = (\delta^* \mu + (1 - \delta^*) \lambda) v$, et ces valeurs sont au moins $\delta^* \mu > 0$. (ii) Avec $a = \delta^* \mu > 0$ et $c = 1 - \delta^*$, l'inégalité $\frac{a+c\lambda_1}{a+c\lambda_N} \leq \frac{\lambda_1}{\lambda_N}$ équivaut à $a\lambda_N \leq a\lambda_1$, qui est vraie. ■

Lemme 3.5 (calcul de $\bar{b}^2$ sans former les $x_t x_t^\top$). $\sum_t \|x_t x_t^\top - S_T\|_F^2 = \sum_t (x_t^\top x_t)^2 - T \|S_T\|_F^2$.

Démonstration. $\|x_t x_t^\top - S_T\|_F^2 = (x_t^\top x_t)^2 - 2x_t^\top S_T x_t + \|S_T\|_F^2$, et $\sum_t x_t^\top S_T x_t = \text{tr}(S_T \sum_t x_t x_t^\top) = T \|S_T\|_F^2$. ■




Fig. 1. Valeurs propres de la vraie covariance, de la covariance empirique et de Ledoit-Wolf (50 actifs, 75 dates). Le shrinkage remonte les petites valeurs propres et divise le conditionnement par 5.

Définition 3.6 (EWMA). Pour une demi-vie h , on pose $\lambda = 2^{-1/h}$ et $\omega_s = \lambda^s / \sum_u \lambda^u$, $s = 0$ désignant la date la plus récente. Alors $\hat{\Sigma} = \sum_s \omega_s (R_{t-s} - \bar{R}_\omega)(R_{t-s} - \bar{R}_\omega)^\top$, avec $\bar{R}_\omega = \sum_s \omega_s R_{t-s}$.

Proposition 3.7. Sur un historique infini, le nombre effectif d'observations $(\sum_s \omega_s)^2 / \sum_s \omega_s^2$ vaut $(1 + \lambda)/(1 - \lambda)$, soit environ 182 pour $h = 63$.

Démonstration. $\sum_s \lambda^s = \frac{1}{1-\lambda}$ et $\sum_s \lambda^{2s} = \frac{1}{1-\lambda^2}$, donc le rapport vaut $\frac{1-\lambda^2}{(1-\lambda)^2} = \frac{1+\lambda}{1-\lambda}$. ■

Dans le code

Toute règle accepte `cov_method="sample" | "ledoit_wolf" | "ewma"` ou une fonction `returns` -> `ndarray`. Directement : `estimate_cov(R, "ledoit_wolf")`, `ledoit_wolf_cov(R)` qui renvoie `(Sigma, delta)`, `ewma_cov(R, halflife=63)`.

En pratique

Aucune règle de la librairie n'utilise les rendements espérés. L'erreur standard d'une moyenne annualisée vaut $\sigma/\sqrt{Y}$ sur Y années, quelle que soit la fréquence ($\pm 5\%$ pour $\sigma = 16\%$ et 10 ans), alors que l'erreur sur une variance diminue avec le nombre d'observations : la covariance s'estime bien mieux que la moyenne.

4 Contributions au risque

Proposition 4.1 (décomposition d'Euler). *Pour tout w tel que $\sigma_p(w) > 0$: $\frac{\partial \sigma_p}{\partial w} = \frac{\Sigma w}{\sigma_p}$ et*

$$\sigma_p(w) = \sum_{i=1}^N w_i \frac{\partial \sigma_p}{\partial w_i}(w).$$

Démonstration. Le gradient s'obtient en dérivant $\sqrt{w^\top \Sigma w}$. Puis $\sum_i w_i (\Sigma w)_i / \sigma_p = w^\top \Sigma w / \sigma_p = \sigma_p$. ■

Définition 4.2 (contributions au risque). Contribution marginale, contribution et contribution relative de l'actif i :

$$\text{MRC}_i = \frac{(\Sigma w)_i}{\sigma_p}, \quad \text{RC}_i = w_i \text{MRC}_i, \quad \frac{\text{RC}_i}{\sigma_p} = \frac{w_i (\Sigma w)_i}{w^\top \Sigma w}.$$

Par la proposition 4.1, les RC_i somment à σ_p et les contributions relatives à 1.

Proposition 4.3. $\text{MRC}_i = \beta_{i,p} \sigma_p = \rho_{i,p} \sigma_i$, où $\beta_{i,p}$ et $\rho_{i,p}$ sont le bêta et la corrélation de l'actif i avec le portefeuille.

Démonstration. $(\Sigma w)_i = \text{Cov}(R_i, w^\top R) = \text{Cov}(R_i, R_p)$. Avec $\beta_{i,p} = \text{Cov}(R_i, R_p) / \sigma_p^2$ et $\rho_{i,p} = \text{Cov}(R_i, R_p) / (\sigma_i \sigma_p)$, on obtient les deux égalités. ■

Un actif pèse dans le risque par son bêta au portefeuille, pas par sa volatilité propre. S'il est négativement corrélé au portefeuille, sa contribution est négative.

Exemple

60/40 actions/obligations, $\sigma_A = 16\%$, $\sigma_O = 6\%$, $\rho = -0.2$:
 $\sigma_p^2 = 0.36 \cdot 0.0256 + 0.16 \cdot 0.0036 - 0.48 \cdot 0.2 \cdot 0.0096 = 0.00887$, soit $\sigma_p = 9.4\%$. Puis
 $(\Sigma w)_A = 0.6 \cdot 0.0256 - 0.4 \cdot 0.00192 = 0.01459$ et $\text{RC}_A / \sigma_p = 0.6 \cdot 0.01459 / 0.00887 = 98.7\%$: un 60/40 en capital est un 99/1 en risque.

Dans le code

```
risk_contributions(w, cov) renvoie les contributions relatives ;
Backtester.risk_contributions() les donne à chaque rebalancement.
```

5 Règles d'allocation

Définition 5.1 (règle d'allocation). Une règle d'allocation est une fonction $\mathcal{A}$ qui associe à une fenêtre de rendements $(R_{t-L}, \dots, R_{t-1})$ un portefeuille $w \in \Delta_N$. Dans la librairie, c'est un `BaseEstimator : est.fit(fenetre).weights_`.

5.1 Equal Weight (1/N)

Définition 5.2. $w_i = 1/N$ pour tout i .

Proposition 5.3. *Si tous les actifs ont la volatilité σ et des corrélations deux à deux égales à ρ , alors $\sigma_{1/N}^2 = \frac{\sigma^2}{N}(1 + (N-1)\rho) \rightarrow \rho\sigma^2$ quand $N \rightarrow \infty$.*

Démonstration. $w^\top \Sigma w = \frac{1}{N^2}(N\sigma^2 + N(N-1)\rho\sigma^2)$. ■

La diversification supprime le risque propre à chaque actif mais pas le risque commun $\rho\sigma^2$. $1/N$ n'estime rien et ne commet donc aucune erreur d'estimation : c'est le benchmark de référence, qu'aucun des 14 modèles d'optimisation testés par [DeMiguel et al. \(2009\)](#) ne bat significativement hors échantillon.

Dans le code
EqualWeight()

5.2 Inverse volatilité

Définition 5.4. $w_i = \sigma_i^{-k} / \sum_j \sigma_j^{-k}$, avec $k = 1$ (inverse volatilité) ou $k = 2$ (inverse variance).

Proposition 5.5. (i) *Si toutes les corrélations sont égales, l'inverse volatilité égalise les contributions au risque : c'est l'ERC (section 5.4).*

(ii) *Si Σ est diagonale, l'inverse variance est le portefeuille de variance minimale.*

Démonstration. (i) Avec $w_i = c/\sigma_i$ et $\rho_{ij} = \rho$ pour $i \neq j$: $(\Sigma w)_i = \sum_j \rho_{ij} \sigma_i \sigma_j c / \sigma_j = c \sigma_i (1 + (N-1)\rho)$, donc $w_i (\Sigma w)_i = c^2 (1 + (N-1)\rho)$ ne dépend pas de i . (ii) Le portefeuille de variance minimale est $w \propto \Sigma^{-1} \mathbf{1}$ et, pour Σ diagonale, $\Sigma^{-1} \mathbf{1} = (\sigma_i^{-2})_i$. ■

Dans le code
InverseVolatility(exponent=1); exponent=2 pour l'inverse variance.

5.3 Risk budgeting

Définition 5.6. Soit des budgets $b_i > 0$ de somme 1. Un portefeuille de risk budgeting est un $w \in \Delta_N$ tel que $w_i (\Sigma w)_i / (w^\top \Sigma w) = b_i$ pour tout i : l'actif i porte la part b_i du risque.

Théorème 5.7 ([Spinu, 2013](#)). Soit $\Sigma \succ 0$ et $f(y) = \frac{1}{2} y^\top \Sigma y - \sum_i b_i \ln y_i$ sur $\mathbb{R}_{++}^N$. Alors f a un unique minimiseur y^* , et $w^* = y^* / \mathbf{1}^\top y^*$ est l'unique portefeuille de risk budgeting.

Démonstration. *Existence.* $f \rightarrow +\infty$ quand un $y_i \rightarrow 0^+$ (terme logarithmique) et quand $\|y\| \rightarrow \infty$ (le terme quadratique, minoré par $\frac{1}{2} \lambda_{\min}(\Sigma) \|y\|^2$, domine). Le minimum est donc atteint à l'intérieur de $\mathbb{R}_{++}^N$. *Unicité.* $\nabla^2 f = \Sigma + \text{diag}(b_i/y_i^2) \succ 0$: f est strictement convexe. *Budgets.* $\partial_i f = (\Sigma y)_i - b_i/y_i = 0$ donne $y_i^* (\Sigma y^*)_i = b_i$. Comme $w_i (\Sigma w)_i$ est homogène de degré 2, les contributions relatives de w^* valent $b_i / \sum_j b_j = b_i$. *Unicité du portefeuille.* Si w convient, $y = w / \sqrt{w^\top \Sigma w}$ vérifie $y_i (\Sigma y)_i = b_i$, donc $\nabla f(y) = 0$, donc $y = y^*$. ■

Proposition 5.8 (mise à jour par coordonnée). À $(y_j)_{j \neq i}$ fixés, le minimiseur de f en $y_i > 0$ est

$$y_i = \frac{-c_i + \sqrt{c_i^2 + 4 \Sigma_{ii} b_i}}{2 \Sigma_{ii}}, \quad c_i = \sum_{j \neq i} \Sigma_{ij} y_j.$$

Démonstration. $\partial_i f = 0$ s'écrit $\Sigma_{ii} y_i^2 + c_i y_i - b_i = 0$. Le produit des racines, $-b_i / \Sigma_{ii}$, est négatif : une seule racine est positive, et c'est celle-ci. ■

En répétant cette mise à jour sur $i = 1, \dots, N$ jusqu'à stabilisation (descente par coordonnées cyclique), on converge vers y^* (admis, [Tseng, 2001](#)).

Algorithm 1 : Risk budgeting par descente par coordonnées (**RiskParity**)

Entrées : $\Sigma \succ 0$, budgets b , tolérance $\varepsilon = 10^{-10}$
Sortie : poids w

```

1  $y_i \leftarrow b_i/\sigma_i$ ;    $y \leftarrow y/\sqrt{y^\top \Sigma y}$ ;    $s \leftarrow \Sigma y$ ;
2 répéter
3    $y^{\text{old}} \leftarrow y$ ;
4   pour  $i \leftarrow 1$  à  $N$  faire
5      $c \leftarrow s_i - \Sigma_{ii} y_i$ ;    $y'_i \leftarrow (-c + \sqrt{c^2 + 4\Sigma_{ii} b_i})/(2\Sigma_{ii})$ ;
6      $s \leftarrow s + \Sigma_{:,i}(y'_i - y_i)$ ;    $y_i \leftarrow y'_i$ ;   # coût  $O(N)$ , sans inversion
7 jusqu'à  $\|y - y^{\text{old}}\| \leq \varepsilon \|y\|$ ;
8 retourner  $w = y/\mathbf{1}^\top y$ 
```

Dans le code

`RiskParity(budgets={"SPY": 1, "TLT": 2, ...})`, un budget strictement positif par actif (normalisés automatiquement); `n_iter_` donne le nombre de cycles.

5.4 Equal Risk Contribution (ERC)

Définition 5.9. L'ERC est le risk budgeting avec $b_i = 1/N$: chaque actif porte la même part du risque.

Théorème 5.10 ([Maillard et al., 2010](#)). Si σ_{MV} est la volatilité du portefeuille long-only de variance minimale, alors $\sigma_{\text{MV}} \leq \sigma_{\text{ERC}} \leq \sigma_{1/N}$.

Démonstration. La première inégalité vient de ce que le min-variance minimise σ_p sur tout Δ_N . Pour la seconde, σ_p est convexe (norme de $\Sigma^{1/2}w$), donc au-dessus de sa tangente en $w = w_{\text{ERC}}$. Avec $\nabla \sigma_p(w)^\top w = \sigma_p(w)$ (proposition 4.1) :

$$\sigma_{1/N} \geq \sigma_{\text{ERC}} + \nabla \sigma_p(w)^\top \left(\frac{1}{N} \mathbf{1} - w\right) = \frac{1}{N} \sum_i \partial_i \sigma_p(w).$$

En ERC, $w_i \partial_i \sigma_p = \sigma_{\text{ERC}}/N$, d'où $\sigma_{1/N} \geq \frac{\sigma_{\text{ERC}}}{N^2} \sum_i \frac{1}{w_i} \geq \sigma_{\text{ERC}}$, car $\sum_i 1/w_i \geq N^2$ sur Δ_N (inégalité arithmético-harmonique). ■

Proposition 5.11. Si tous les actifs ont le même ratio de Sharpe et des corrélations égales, l'ERC est le portefeuille de Sharpe maximal.

Démonstration. Le portefeuille de Sharpe maximal est $w \propto \Sigma^{-1}\mu$. Avec $\mu_i = s\sigma_i$, $\Sigma = DCD$, $D = \text{diag}(\sigma_i)$ et $C = (1-\rho)I + \rho\mathbf{1}\mathbf{1}^\top$: comme $C\mathbf{1} = (1+(N-1)\rho)\mathbf{1}$, on a $\Sigma^{-1}\mu = sD^{-1}C^{-1}\mathbf{1} \propto D^{-1}\mathbf{1}$. C'est l'inverse volatilité, égale à l'ERC par la proposition 5.5. ■

Dans le code

`ERC(cov_method="ledoit_wolf")`

5.5 Hierarchical Risk Parity (HRP)

HRP ([López de Prado, 2016](#)) regroupe les actifs qui se ressemblent, puis répartit le capital entre groupes avant de le répartir dans chaque groupe. Il n'inverse jamais Σ .




Fig. 2. Deux actifs ($\sigma_1 = 18\%$, $\sigma_2 = 6\%$, $\rho = -0.2$). L'ERC a une volatilité proche du minimum (5.7% contre 5.3%) mais répartit le risque à parts égales, alors que 1/N en met 95% sur l'actif risqué.

Définition 5.12 (distance de corrélation). $d_{ij} = \sqrt{\frac{1}{2}(1 - \rho_{ij})} \in [0, 1]$.

Proposition 5.13. d est une distance, nulle si et seulement si $\rho_{ij} = 1$.

Démonstration. Soit z_i la série de l'actif i centrée et de norme 1. Alors $\rho_{ij} = z_i^\top z_j$ et $\|z_i - z_j\|^2 = 2 - 2\rho_{ij}$, donc $d_{ij} = \frac{1}{2}\|z_i - z_j\|$ hérite des propriétés de la norme euclidienne. ■

Définition 5.14 (HRP). 1. *Clustering* : classification hiérarchique des actifs selon d (méthode linkage), qui produit un arbre binaire.

2. *Quasi-diagonalisation* : on ordonne les actifs selon les feuilles de l'arbre, ce qui place côte à côte les actifs corrélés.

3. *Bissection* : on part de $w = \mathbf{1}$ et on découpe récursivement chaque groupe en deux sous-groupes L et R (deux moitiés de la liste ordonnée, ou les deux branches de l'arbre). À chaque découpe,

$$\alpha = \frac{V_R}{V_L + V_R}, \quad w_L \leftarrow \alpha w_L, \quad w_R \leftarrow (1 - \alpha) w_R,$$

où $V_c = \tilde{w}_c^\top \Sigma_c \tilde{w}_c$ est la variance du portefeuille inverse variance du groupe c , avec $\tilde{w}_c \propto \text{diag}(\Sigma_c)^{-1}$.

Chaque sous-groupe reçoit une part inversement proportionnelle à sa variance. Les $\tilde{w}_c$ servent uniquement à calculer V_c : les poids finaux résultent des découpes successives, jusqu'aux actifs individuels.

Proposition 5.15. (i) *HRP renvoie un portefeuille de Δ_N et n'inverse que des diagonales : il fonctionne même si Σ est singulière.*

(ii) *Si Σ est diagonale, HRP est le portefeuille inverse variance.*

Démonstration. (i) Avant qu'un groupe c soit découpé, tous ses actifs portent le même poids m_c (ils ont subi les mêmes multiplications), avec $m = 1$ pour l'univers entier. Une découpe donne $m_L = \alpha m_c$ et $m_R = (1 - \alpha)m_c$ avec $\alpha \in (0, 1)$ puisque $V_L, V_R > 0$. Par récurrence sur l'arbre, la somme des poids finaux des actifs de c vaut m_c : pour un actif seul c'est immédiat, et sinon elle vaut $m_L + m_R = m_c$. Pour l'univers, la somme vaut 1 et tous les poids sont positifs. (ii) Pour Σ diagonale, $V_c = 1/S_c$ avec $S_c = \sum_{i \in c} \sigma_i^{-2}$, donc $\alpha = S_L/(S_L + S_R)$: chaque groupe reçoit la part d'inverse variance de ses actifs, et par récurrence l'actif i reçoit $\sigma_i^{-2}/\sum_j \sigma_j^{-2}$. ■




Fig. 3. Étapes de HRP sur l'univers simulé : corrélations dans un ordre arbitraire, arbre, corrélations réordonnées. Deux blocs apparaissent : taux et crédit en haut, actifs risqués en bas.

Dans le code

`HRP(linkage="single", split="bisection")` reproduit l'article original ; `split="dendrogram"` suit les branches de l'arbre au lieu de couper la liste en deux moitiés. Attributs : `order_` (ordre des feuilles), `linkage_matrix_` (arbre).

En pratique

L'arbre peut changer d'un rebalancement à l'autre : HRP est plus instable qu'ERC (turnover 2.5 fois plus élevé dans l'exemple). Les méthodes "average" ou "ward" donnent des arbres plus stables que "single".

5.6 Synthèse

	1/N	InvVol	Risk budgeting, ERC	HRP
Utilise σ_i	non	oui	oui	oui
Utilise ρ_{ij}	non	non	oui	oui, via l'arbre
Inverse Σ	non	non	non	non
Calcul	direct	direct	itératif, solution unique	direct
Ce qui est égalisé	le capital	$w_i \sigma_i$	$w_i (\Sigma w)_i$	la variance entre groupes
Résultats	prop. 5.3	prop. 5.5	th. 5.7, 5.10	prop. 5.15

6 Backtest walk-forward

Définition 6.1 (backtest walk-forward). Soit une règle $\mathcal{A}$, une fenêtre L et une période de détention H . Les dates de rebalancement sont $t_k = L + kH$. À chaque t_k , on calcule $w^{(k)} = \mathcal{A}(R_{t_k-L}, \dots, R_{t_k-1})$ (fenêtre glissante) ou $\mathcal{A}(R_0, \dots, R_{t_k-1})$ (fenêtre croissante), puis on détient ce portefeuille jusqu'à $t_{k+1} - 1$.

Walk-forward backtest (rolling window)

Weights fitted on returns up to $t-1$ are held on $[t, t+H]$, then the window rolls by H




Fig. 4. Estimation sur $[t - L, t)$, détention sur $[t, t + H)$, puis décalage de H .

Proposition 6.2 (absence d'anticipation). *Le portefeuille qui gagne le rendement R_t ne dépend que de $R_0, \dots, R_{t-1}$.*

Démonstration. Si $t_k \leq t < t_{k+1}$, R_t est gagné avec $w^{(k)}$ dérivé jusqu'en $t - 1$ (définition ci-dessous). $w^{(k)}$ ne dépend que de rendements antérieurs à $t_k \leq t$, et la dérive que de $R_{t_k}, \dots, R_{t-1}$. ■

Définition 6.3 (dérive des poids). Entre deux rebalancements, les quantités détenues ne changent pas. k jours après le rebalancement ($V_0 = 1$) :

$$V_k = \sum_i w_i \prod_{s=1}^k (1 + R_{i,s}), \quad R_{p,k} = \frac{V_k}{V_{k-1}} - 1.$$

Proposition 6.4. *Le poids de l'actif i après k jours est $w_i^{(k)} = w_i \prod_{s \leq k} (1 + R_{i,s}) / V_k$, et $R_{p,k} = \sum_i w_i^{(k-1)} R_{i,k}$.*

Démonstration. La ligne i vaut $w_i \prod_{s \leq k} (1 + R_{i,s})$ et son poids est cette valeur divisée par V_k . Ensuite $\frac{V_k}{V_{k-1}} = \sum_i \frac{w_i \prod_{s \leq k} (1 + R_{i,s})}{V_{k-1}} (1 + R_{i,k}) = \sum_i w_i^{(k-1)} (1 + R_{i,k})$: c'est la proposition 2.3 avec les poids dérivés. ■

Définition 6.5 (turnover et coûts). Au rebalancement, le turnover est $\tau = \sum_i |w_i^{\text{cible}} - w_i^{\text{dérivé}}|$, mesuré par rapport aux poids *dérivés* et non à la cible précédente. Avec un coût proportionnel c , la richesse est multipliée par $1 - c\tau$. Le turnover annualisé est la somme des τ , hors construction initiale, divisée par le nombre d'années.

Le coût annuel vaut donc environ c fois le turnover annualisé : 120 % de turnover à 10 bps coûtent 12 bps par an.

Algorithm 2 : Backtest walk-forward (Backtester.run)

Entrées : rendements R , règle $\mathcal{A}$, L , H , coût c

Sortie : rendements hors échantillon nets de coûts

```

1  $w^{\text{dérivé}} \leftarrow 0$ ;  $t \leftarrow L$ ; # départ en cash
2 tant que  $t < T$  faire
3   actifs éligibles  $\leftarrow$  actifs sans valeur manquante sur la fenêtre;
4    $w \leftarrow \mathcal{A}(\text{fenêtre})$ ;  $\tau \leftarrow \sum_i |w_i - w_i^{\text{dérivé}}|$ ;
5   détenir  $w$  sur  $[t, t + H)$  avec dérive; richesse  $\times (1 - c\tau)$  en  $t$ ;
6    $w^{\text{dérivé}} \leftarrow$  poids en fin de période;  $t \leftarrow t + H$ ;

```

Dans le code

```
bt = Backtester(R, ERC(), in_sample=252, out_of_sample=21,
transaction_cost_bps=5); bt.run() renvoie les rendements nets. Attributs weights_,
turnover_, gross_returns_; méthodes annualized_turnover() et risk_contributions().
Options : window="expanding", drift=False (rebalancement quotidien gratuit vers la cible).
run_backtests compare plusieurs règles sur la même grille.
```

7 Indicateurs de performance

Les fonctions de `portopt.metric` prennent une série de rendements simples (`pd.Series`) ou un tableau avec une colonne par stratégie (`pd.DataFrame`).

Définition 7.1 (rendement total, CAGR). $TR = \prod_{t=1}^T (1 + R_t) - 1$ et $CAGR = (1 + TR)^{P/T} - 1$: le taux annuel constant qui mène à la même richesse finale.

Proposition 7.2 (volatility drag). *Le taux de croissance $g = \ln(1 + CAGR)$ vérifie, au second ordre, $g \approx \mu_{\text{ann}} - \frac{1}{2}\sigma_{\text{ann}}^2$.*

Démonstration. $g = \frac{P}{T} \sum_t \ln(1 + R_t)$ et $\ln(1 + R) = R - \frac{R^2}{2} + O(R^3)$. Comme $\frac{1}{T} \sum_t R_t^2 = \hat{\sigma}^2 + \bar{R}^2 \approx \hat{\sigma}^2$ en quotidien, $g \approx P\bar{R} - \frac{P}{2}\hat{\sigma}^2 = \mu_{\text{ann}} - \frac{1}{2}\sigma_{\text{ann}}^2$. ■

À moyenne égale, la stratégie la moins volatile finit plus riche. Dans l'exemple, $1/N$ a $\mu_{\text{ann}} = 7.36\%$ et $\sigma_{\text{ann}} = 11.42\%$: la formule donne $g = 6.71\%$, pour 6.70% observé.

Définition 7.3 (ratio de Sharpe). Avec un taux sans risque annuel r_f converti par période, $SR = \sqrt{P} (\bar{R} - r_f) / \hat{\sigma}$.

Proposition 7.4. *Le Sharpe est invariant au levier : multiplier les rendements excédentaires par $k > 0$ ne le change pas. Sous les hypothèses de la proposition 2.6, le Sharpe annuel vaut $\sqrt{P}$ fois le Sharpe par période.*

Démonstration. La moyenne et l'écart-type de kX valent k fois ceux de X . En annuel, le ratio devient $P\mu/(\sqrt{P}\sigma) = \sqrt{P}\mu/\sigma$. ■

Définition 7.5 (ratio de Sortino). Pour un seuil τ par période,

$$\text{Sortino} = \sqrt{P} \frac{\bar{R} - \tau}{DD_\tau}, \quad DD_\tau = \sqrt{\frac{1}{T} \sum_{t=1}^T \min(R_t - \tau, 0)^2}.$$

La moyenne des carrés porte sur *toutes* les dates, les gains comptant pour zéro. Le Sortino est le rendement moyen par unité de risque de baisse.

Proposition 7.6. (i) Pour $\tau = 0$, le Sortino est invariant au levier.

(ii) Si $R \sim \mathcal{N}(\mu, \sigma^2)$, $\tau = 0$ et $m = \mu/\sigma$:

$$\frac{\text{Sortino}}{SR} = \frac{1}{\sqrt{(1 + m^2) \Phi(-m) - m\varphi(m)}} = \sqrt{2} \left(1 + \sqrt{2/\pi} m \right) + O(m^2).$$

Démonstration. (i) Pour $k > 0$, $\min(kR, 0) = k \min(R, 0)$: numérateur et dénominateur sont multipliés par k . (ii) Le rapport vaut σ/DD_0 . Avec $R = \sigma(m + Z)$ et $Z \sim \mathcal{N}(0, 1)$, $DD_0^2 = \sigma^2 \mathbb{E}[(m + Z)^2 \mathbf{1}_{Z < -m}]$. Les identités $\mathbb{E}[Z \mathbf{1}_{Z < a}] = -\varphi(a)$ et $\mathbb{E}[Z^2 \mathbf{1}_{Z < a}] = \Phi(a) - a\varphi(a)$, prises en $a = -m$, donnent $m^2\Phi(-m) - 2m\varphi(m) + \Phi(-m) + m\varphi(m)$, d'où la formule. Pour le

développement, $\Phi(-m) = \frac{1}{2} - \varphi(0)m + O(m^2)$ et $\varphi(m) = \varphi(0) + O(m^2)$ avec $\varphi(0) = 1/\sqrt{2\pi}$, donc le radicande vaut $\frac{1}{2} - 2\varphi(0)m + O(m^2)$. ■

Pour une loi symétrique, le Sortino vaut donc environ $\sqrt{2} \approx 1.41$ fois le Sharpe si la moyenne est nulle, un peu plus si elle est positive. Dans l'exemple (Sharpe quotidien de 0.04 à 0.055), une gaussienne donnerait 1.46 à 1.48 ; on observe 1.44 à 1.51. Le Sortino n'apporte alors presque rien de plus que le Sharpe. Il devient informatif pour des stratégies nettement asymétriques.

Définition 7.7 (Calmar, hit ratio). $\text{Calmar} = \text{CAGR}/|\text{MaxDD}|$ (MaxDD défini en section 8) et $\text{Hit} = \frac{1}{T} \sum_t \mathbf{1}_{R_t > 0}$.

Dans le code

```
cagr, annualized_mean, annualized_volatility, sharpe_ratio(r, rf=0.0) ( $r_f$  annuel),
sortino_ratio(r, target=0.0) (seuil par période), calmar_ratio, hit_ratio. summary(rets)
les réunit dans un tableau.
```

8 Indicateurs de risque

Définition 8.1 (drawdown). Avec la richesse $W_t = \prod_{s \leq t} (1 + R_s)$ et $W_0 = 1$:

$$DD_t = \frac{W_t}{\max(1, \max_{s \leq t} W_s)} - 1, \quad \text{MaxDD} = \min_t DD_t.$$

La durée maximale sous l'eau est la plus longue suite de dates consécutives où $DD_t < 0$.

Le capital initial compte comme un sommet : perdre 10 % le premier jour donne un drawdown de -10 %.

Proposition 8.2. Après une perte $\ell \in (0, 1)$, il faut un gain $\ell/(1 - \ell)$ pour revenir au niveau initial.

Démonstration. $(1 - \ell)(1 + g) = 1 \iff g = \ell/(1 - \ell)$. Ainsi -20 % demande +25 %, et -50 % demande +100 %. ■



Fig. 5. Sommet, creux, récupération et durée sous l'eau du plus grand drawdown du portefeuille 1/N.

Le MaxDD s'aggrave mécaniquement avec la durée observée : pour un mouvement brownien sans dérive, son espérance croît comme $\sigma\sqrt{T}$ (admis, [Magdon-Ismail et al., 2004](#)). On ne compare donc des MaxDD que sur une même période.

Définition 8.3 (VaR et CVaR historiques). Avec q_α le quantile empirique d'ordre α des rendements : $\text{VaR}_\alpha = -q_\alpha$ et $\text{CVaR}_\alpha = -\mathbb{E}[R \mid R \leq q_\alpha]$, exprimées en pertes positives. La CVaR est la perte moyenne sur la fraction α des pires dates.

Proposition 8.4. (i) $\text{CVaR}_\alpha \geq \text{VaR}_\alpha$.

(ii) La VaR n'est pas sous-additive : on peut avoir $\text{VaR}(A + B) > \text{VaR}(A) + \text{VaR}(B)$.

(iii) La CVaR est sous-additive ; c'est une mesure de risque cohérente (admis, [Artzner et al., 1999](#)).

Démonstration. (i) Sur l'événement $\{R \leq q_\alpha\}$, $-R \geq -q_\alpha$; on prend l'espérance conditionnelle. (ii) Deux obligations indépendantes perdent chacune 100 avec probabilité 4 %, 0 sinon. Pour chacune, $\text{VaR}_{95\%} = 0$. Pour leur somme, la perte vaut 0, 100 ou 200 avec probabilités 92.16 %, 7.68 % et 0.16 % : $\text{VaR}_{95\%} = 100 > 0 + 0$. ■

Dans cet exemple, $\text{CVaR}_{95\%} = 80$ pour chaque obligation et $103.2 \leq 160$ pour la somme : la CVaR récompense bien la diversification.

Daily return distribution and tail risk

1/N portfolio, excess kurtosis 14.1: the normal curve underestimates the tail (shaded)




Fig. 6. Rendements quotidiens de 1/N, VaR et CVaR à 95 %. La loi normale de même moyenne et variance sous-estime la queue gauche.

Définition 8.5 (asymétrie et aplatissement). $\gamma_3 = \mathbb{E}[(R - \mu)^3]/\sigma^3$ et $\gamma_4 = \mathbb{E}[(R - \mu)^4]/\sigma^4$; la kurtosis excédentaire $\gamma_4 - 3$ est nulle pour une loi normale.

$\gamma_3 < 0$ signale des pertes rares mais fortes, $\gamma_4 - 3 > 0$ des queues plus épaisses qu'une loi normale. Ces moments dépendent de quelques jours extrêmes : on les vérifie sur des sous-périodes.

Dans le code

```
drawdown_series, max_drawdown, max_drawdown_duration, value_at_risk(r, alpha=0.05),
conditional_value_at_risk, skewness, excess_kurtosis.
```

9 Significativité statistique

Un backtest est une seule trajectoire : un écart de performance n'a de sens que s'il dépasse le bruit d'estimation.

Proposition 9.1 (erreur standard du Sharpe). *Pour des rendements indépendants de loi normale et de Sharpe par période SR, le Sharpe estimé sur T périodes vérifie $\text{Var}(\widehat{\text{SR}}) \approx (1 + \frac{1}{2}\text{SR}^2)/T$. En annuel, sur Y années, $\text{se}(\widehat{\text{SR}}_{\text{ann}}) \approx \sqrt{(1 + \frac{1}{2}\text{SR}^2)/Y} \approx 1/\sqrt{Y}$.*

Démonstration. Pour une loi normale, $\hat{\mu}$ et $\hat{\sigma}^2$ sont indépendants, avec $\text{Var}(\hat{\mu}) = \sigma^2/T$ et $\text{Var}(\hat{\sigma}^2) \approx 2\sigma^4/T$. Pour $g(\mu, \sigma^2) = \mu/\sqrt{\sigma^2}$, on a $\partial_{\mu}g = 1/\sigma$ et $\partial_{\sigma^2}g = -\mu/(2\sigma^3)$. La méthode delta donne $\text{Var}(\widehat{\text{SR}}) \approx \frac{1}{T} + \frac{\mu^2}{4\sigma^6} \cdot \frac{2\sigma^4}{T} = \frac{1+\text{SR}^2/2}{T}$. En annuel, $\widehat{\text{SR}}_{\text{ann}} = \sqrt{P}\widehat{\text{SR}}$ et $T = PY$. ■




Fig. 7. Bande de confiance à 95 % du Sharpe estimé selon la longueur de l'historique.

Un Sharpe de 0.5 n'est significativement positif qu'après $(1.96/0.5)^2 \approx 15$ ans. Dans l'exemple, les Sharpe vont de 0.64 à 0.88 sur 14 ans, pour une erreur standard d'environ 0.27 : les écarts entre stratégies ne sont pas significatifs.

Définition 9.2 (Probabilistic Sharpe Ratio). Avec $\widehat{\text{SR}}$ et un seuil SR^* exprimés par période, et γ_3, γ_4 la skewness et la kurtosis (non excédentaire) des rendements,

$$\text{PSR}(\text{SR}^*) = \Phi \left(\frac{(\widehat{\text{SR}} - \text{SR}^*)\sqrt{T-1}}{\sqrt{1 - \gamma_3\widehat{\text{SR}} + \frac{\gamma_4-1}{4}\widehat{\text{SR}}^2}} \right).$$

C'est la probabilité que le vrai Sharpe dépasse SR^* , compte tenu de l'asymétrie et des queues épaisses (admis, [Bailey et López de Prado, 2012](#)). Pour $\gamma_3 = 0$ et $\gamma_4 = 3$, on retrouve la proposition 9.1.

Définition 9.3 (Deflated Sharpe Ratio). Si K variantes ont été testées et la meilleure retenue, le DSR est le PSR calculé avec le seuil

$$\text{SR}_K^* = \sqrt{\text{Var}(\widehat{\text{SR}}_k)} \left[(1 - \gamma_E) \Phi^{-1}\left(1 - \frac{1}{K}\right) + \gamma_E \Phi^{-1}\left(1 - \frac{1}{K^e}\right) \right],$$

qui approche l'espérance du maximum de K Sharpe nuls, avec $\gamma_E \approx 0.5772$ (admis, [Bailey et López de Prado, 2014](#)).

Pour $K = 100$, le crochet vaut environ 2.53 : il faut un Sharpe observé d'au moins 2.5 erreurs standard pour écarter l'effet de la sélection du meilleur essai.

Dans le code

```
probabilistic_sharpe_ratio(r, sr_benchmark=0.0); le seuil est donné en annuel et converti en interne. summary affiche PSR(SR>0).
```

10 Exemple complet

`python examples/run_backtest.py --synthetic` : 10 ETF simulés, fenêtre de 252 jours, rebalancement tous les 21 jours, coûts de 5 bps, de décembre 2010 à juin 2024.

	1/N	InvVol	RB bond tilt	ERC	ERC LW	HRP
CAGR	6.9 %	6.6 %	6.1 %	6.2 %	6.2 %	6.1 %
Volatilité	11.4 %	8.9 %	7.7 %	8.2 %	8.4 %	7.0 %
Sharpe	0.64	0.76	0.81	0.77	0.76	0.88
Max DD	-27.3 %	-20.5 %	-18.0 %	-19.0 %	-19.5 %	-15.0 %
CVaR 95 % (jour)	1.7 %	1.3 %	1.1 %	1.2 %	1.2 %	1.0 %
Turnover annuel	38 %	41 %	45 %	49 %	48 %	120 %

Tab. 1. Indicateurs hors échantillon, nets de coûts. RB bond tilt double le budget de risque de TLT, IEF et LQD ; ERC LW utilise Ledoit-Wolf.



Fig. 8. Croissance de 1 hors échantillon, nette de coûts.

Lecture.

1. Par rapport à 1/N, les règles fondées sur le risque réduisent la volatilité de 20 à 40 % et le drawdown de 25 à 45 %. 1/N garde le meilleur CAGR car il est plus exposé aux actifs risqués.
2. Les écarts de Sharpe entre règles sont inférieurs à une erreur standard (proposition 9.1) : ce backtest ne permet pas de les classer.
3. Avec 10 actifs et 252 dates, le shrinkage de Ledoit-Wolf est faible (δ^* médian de 4 %) et change peu le résultat.

Average risk allocation

Mean relative risk contribution, in-sample covariance at each rebalancing

	SPY	EFA	EEM	IWM	TLT	IEF	LQD	GLD	DBC	VNQ
1/N	13%	14%	18%	17%	0%	0%	3%	6%	11%	17%
InvVol	12%	13%	13%	12%	4%	5%	11%	8%	9%	13%
RB bond tilt	8%	8%	8%	8%	15%	15%	15%	8%	8%	8%
ERC	10%	10%	10%	10%	10%	10%	10%	10%	10%	10%
ERC LW	10%	10%	10%	10%	10%	9%	10%	10%	10%	10%
HRP	2%	4%	4%	2%	10%	31%	30%	10%	3%	5%

Fig. 9. Contributions relatives moyennes au risque. 1/N met 79 % du risque sur les actifs de type actions, ERC l'égalise, HRP en concentre 71 % sur les trois ETF obligataires.

4. HRP a le turnover le plus élevé, conséquence de l'instabilité de l'arbre.

Références

- Artzner, P., Delbaen, F., Eber, J.-M., Heath, D. (1999). Coherent measures of risk. *Mathematical Finance*, 9(3), 203–228.
- Bailey, D. H., López de Prado, M. (2012). The Sharpe ratio efficient frontier. *Journal of Risk*, 15(2), 3–44.
- Bailey, D. H., López de Prado, M. (2014). The deflated Sharpe ratio : correcting for selection bias, backtest overfitting and non-normality. *Journal of Portfolio Management*, 40(5), 94–107.
- DeMiguel, V., Garlappi, L., Uppal, R. (2009). Optimal versus naive diversification : how inefficient is the $1/N$ portfolio strategy ? *Review of Financial Studies*, 22(5), 1915–1953.
- Ledoit, O., Wolf, M. (2004). A well-conditioned estimator for large-dimensional covariance matrices. *Journal of Multivariate Analysis*, 88(2), 365–411.
- López de Prado, M. (2016). Building diversified portfolios that outperform out of sample. *Journal of Portfolio Management*, 42(4), 59–69.
- Magdon-Ismaïl, M., Atiya, A. F., Pratap, A., Abu-Mostafa, Y. S. (2004). On the maximum drawdown of a Brownian motion. *Journal of Applied Probability*, 41(1), 147–161.
- Maillard, S., Roncalli, T., Teiletche, J. (2010). The properties of equally weighted risk contribution portfolios. *Journal of Portfolio Management*, 36(4), 60–70.
- Marchenko, V. A., Pastur, L. A. (1967). Distribution of eigenvalues for some sets of random matrices. *Mathematics of the USSR-Sbornik*, 1(4), 457–483.
- Spinu, F. (2013). An algorithm for computing risk parity weights. SSRN 2297383.
- Tseng, P. (2001). Convergence of a block coordinate descent method for nondifferentiable minimization. *Journal of Optimization Theory and Applications*, 109(3), 475–494.